


Kvantitative og kvalitative metoder

Hvordan analysere kvantitativ informasjon?

- Univariat analyse (en variabel) ([kapittel 14.1-14.3](#))
- Bivariat analyse (to variabler sammen) ([kapittel 14.4](#))

Njål Andersen



Univariat analyse (beskriv data/informasjon i en variabel)

1. Frekvens - hvor mange (absolutt og relativt) har svart på de ulike alternativene?
2. Sentraltendens (hva er det typiske svaret?)
 - Modus
 - Median
 - Gjennomsnitt
3. Spredning (variasjon rundt sentraltendensen)
 - Normert modalprosent
 - Minimum-/maksimumsverdier
 - Variasjonsbredde
 - Varians
 - Standardavvik


1. Frekvens

Absolutt og relativ fordeling av svar

Tabell 14.1 Absolutt og relativ fordeling på spørsmålet «Hvordan vil du karakterisere ditt forhold til din nærmeste overordnede?» (N = 200)

Svaralternativer	Antall respondenter
Meget godt (5)	n = 50
Godt (4)	n = 60
Verken godt eller dårlig (3)	n = 30
Dårlig (2)	n = 30
Svært dårlig (1)	n = 30

Forhold til leder




■ Meget godt ■ Godt ■ Verken godt eller dårlig ■ Dårlig ■ Svært dårlig

Absolutt og relativ fordeling av svar

Tabell 14.1 Absolutt og relativ fordeling på spørsmålet «Hvordan vil du karakterisere ditt forhold til din nærmeste overordnede?» (N = 200)

Svaralternativer	Antall respondenter	Proporsjon	Prosent (proporsjon x 100)
Meget godt (5)	n = 50	$(50/200) = 0,25$	$(0,25 \times 100) = 25 \%$
Godt (4)	n = 60	$(60/200) = 0,30$	$(0,30 \times 100) = 30 \%$
Verken godt eller dårlig (3)	n = 30	$(30/200) = 0,15$	$(0,15 \times 100) = 15 \%$
Dårlig (2)	n = 30	$(30/200) = 0,15$	$(0,15 \times 100) = 15 \%$
Svært dårlig (1)	n = 30	$(30/200) = 0,15$	$(0,15 \times 100) = 15 \%$

Forhold til leder



■ Meget godt ■ Godt ■ Verken godt eller dårlig ■ Dårlig ■ Svært dårlig


Absolutt og relativ fordeling av svar (stolpediagram)

Tabell 14.1 Absolutt og relativ fordeling på spørsmålet «Hvordan vil du karakterisere ditt forhold til din nærmeste overordnede?» (N = 200)


Svaralternativer	Antall respondenter	Proporsjon	Prosent (proporsjon x 100)
Meget godt (5)	n = 50	$(50/200) = 0,25$	$(0,25 \times 100) = 25 \%$
Godt (4)	n = 60	$(60/200) = 0,30$	$(0,30 \times 100) = 30 \%$
Verken godt eller dårlig (3)	n = 30	$(30/200) = 0,15$	$(0,15 \times 100) = 15 \%$
Dårlig (2)	n = 30	$(30/200) = 0,15$	$(0,15 \times 100) = 15 \%$
Svært dårlig (1)	n = 30	$(30/200) = 0,15$	$(0,15 \times 100) = 15 \%$

Stolpediagram: når det er få alternativer

- Likert skala (1-5, 1-7, etc.)
- Kategoriske variabler (boligtype, sosial media kanal)



Svar fordeling - histogram



Figur 14.3 Fordeling på spørsmålet «Hva er din alder» (N = 2896). Histogram.

2. Sentraltendens

.. Hvor «midten» i dataen er

Type variable og mulige sentraltendens mål

- Kategorisk (nominalt)
 - F.eks. foretrekker du storfe, lam, kylling, fisk eller vegan
- Rangordning (ordinalt)
 - F.eks. sett rekkefølgen du foretrekker følge drikker: Coca Cola, Solo, Urge, Red Bull, kaffe og vann.
 - Kan ikke si noe om hvor mye bedre første-valget er enn andre valg
- Metrisk (forholdstall)
 - F.eks. alder, høyde, inntekt
 - Kan si noe om relative verdier
- Binært
 - F.eks. «er du fysisk til stedet»?
 - Kun to alternativer

Tabell 14.3 Sammenheng mellom ulike statistiske mål på sentraltendens og variablers målenivå

		Mål på sentraltendens		
		Modus	Median	Gjennomsnitt
Målenivå	Kategorisk (nominalt)	x		
	Rangordning (ordinalt)	x	x	(x)
	Metrisk (forholdstall)	x	x	x


Mål på sentraltendens og type variable

- **Modus:** alternative flest har valgt/mest vanlig
- **Median:** punktet der 50% er over og 50% under – midtpunktet
- **Gjennomsnitt / (mean):** Snittverdi av alle svar

Tabell 14.3 Sammenheng mellom ulike statistiske mål på sentraltendens og variablers målenivå

		Mål på sentraltendens		
		Modus	Median	Gjennomsnitt
Målenivå	Kategorisk (nominalt)	x		
	Rangordning (ordinalt)	x	x	(x)
	Metrisk (forholdstall)	x	x	x


Fordeling av alder: median og modus



Figur 14.6 Fordeling på variabelen alder i form av stolpediagram. Modus og median angitt.


Hva sier hver av disse? Hva sier de samlet? Hva mest informativ? Hva mer ønsker vi?

Figure 1. Distribution of Household Income, 2019



Source: U.S. Census Bureau, *Annual Social and Economic Supplement*, available at <https://www.census.gov/data/tables/time-series/demo/income-poverty/cps-hinc/hinc-06.html>.

Forskjell på sentraltendser: antall underordnede



Figur 14.7 Fordeling på variabelen «antall underordnede» i form av stolpediagram. Modus, median og gjennomsnitt angitt.

3. Spredning av observasjoner

Mål på spredning


- Normert modalprosent
 - Hvilken andel som er på modalen
- Minimum- maksimum
 - Lavest og høyest verdi
- Variasjonsbredde
 - Forskjell på høyest og lavest
- Standardavvik
 - Mål på spredning i svarene

Tabell 14.4 Sammenheng mellom ulike statistiske mål på spredning og variablers målenivå

		Mål på spredning			
		Normert modalprosent	Minimum – maksimum	Variasjonsbredde	Standardavvik
Målenivå	Kategorisk (nominalt)	x			
	Rangordning (ordinalt)	x	x	x	(x)
	Metrisk (forholdstall)	x	x	x	x

Standardavvik (ca. tall)


- Ca. 68,2% av alle svar er innenfor +/- **ett standardavvik**
- Ca. 95,4% av alle svar er innenfor +/- to standardavvik




Indikerer hvordan fordelingen ser ut

- Sort linje:
 - fordeling av svært lav standardavvik
- Turkis linje
 - fordeling har stort standardavvik

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$





Figur 14.8 Fordeling på variabelen alder i form av stolpediagram. Gjennomsnitt og ulike mål på spredning angitt.


Tilbakemelding etter arbeidskrav (O&L 2023)

	count	mean
Informasjon på Blackboard / e-post	61	5.9
Mengde forelesning	61	5.4
Bruk av Mentimeter	61	6.0
Lange (5-10; min) oppgaver i timen	61	5.8
Korte (1-2 min) oppgaver i timen, med muntlig svar	61	5.7
Bruk av summegrupper	58	5.3
Tid satt av i timen til å arbeide med caseoppgaver i grupper eller individuelt	61	6.6
Hvor godt fungerte det med at Njål løser case sammen med en student / studtengruppe	58	6.8
Studietips og råd	61	6.7
Hvor tydelig syns du kursholder (Njål) presenterer faget?	60	7.3
Hvor enkelt er det å følge forelesningene?	61	6.7
Hvor tilgjengelig for tilbakemelding opplever du at kursholder (Njål) er?	61	8.4


Tilbakemelding etter arbeidskrav (O&L 2023)

	count	mean	std	min	max	Skala
Informasjon på Blackboard / e-post	61	5.9	1.8	2	10	5=Passe
Mengde forelesning	61	5.4	1.4	2	9	5=Passe
Bruk av Mentimeter	61	6.0	1.8	2	10	5=Passe
Lange (5-10; min) oppgaver i timen	61	5.8	2.2	1	10	5=Passe
Korte (1-2 min) oppgaver i timen, med muntlig svar	61	5.7	2.1	1	10	5=Passe
Bruk av summegrupper	58	5.3	2.5	1	10	5=Passe
Tid satt av i timen til å arbeide med caseoppgaver i grupper eller individuelt	61	6.6	2.2	1	10	5=Passe
Hvor godt fungerte det med at Njål løser case sammen med en student / studtengruppe	58	6.8	2.3	1	10	5=Passe
Studietips og råd	61	6.7	2.5	1	10	5=Passe
Hvor tydelig syns du kursholder (Njål) presenterer faget?	60	7.3	2.2	0	10	10=Svært tydelig
Hvor enkelt er det å følge forelesningene?	61	6.7	2.0	2	10	10= Svært enkelt
Hvor tilgjengelig for tilbakemelding opplever du at kursholder (Njål) er?	61	8.4	2.1	2	10	10= Svært tilgjengelig


Mengde forelesning




Bruk av summegrupper




Informasjon på Blackboard / e-post



Hvor enkelt er det å følge forelesningene?




Studietips og råd



Det er mange måter å visualisere data på..


Alternative visualisering.. «Violin plot»

Merk: de grå stiplede linjene representerer (fra venstre til høyre): 25 percentile, Median, 75 percentile)




Violin plot, all variables, truncated to possible range

«Passe
Mengde»



Sammenlikning med resultater fra i 2022



Bivariat Analyse

Samvariasjon mellom to variabler

- Krysstabeller
- Sammenligning av gjennomsnitt
- Spredningsdiagram
- Korrelasjonsanalyse

Hypoteseutvikling

Slutningsstatistikk/statistisk generalisering

Bivariat analyse – oversikt

- Krysstabeller
- Spredningsplott
- Statistiske mål på samvariasjon
 - Phi
 - Pearsons r (produktmomentkorrelasjonskoeffisienten)
 - Gamma
 - Kendall Tau
 - Rho (rangkorrelasjonskoeffisienten)

Krysstabeller

- Viser frekvens av observasjoner, organisert etter **kategori** og variabel
 - Kombinerer data for (minst) to variabler
- Viser forhold og mønster i dataen
- Kan brukes for å teste statistisk om forhold mellom variabler

Krysstabeller – eksempel

- “Are you considering staying in Norway when you finish your degree/program?”
- NB! N=802 (analysen er kun gjort for de som avlegger grad i Norge, utvekslingsstudenter ikke inkludert i analysen, jf. q50)

Variable 1

Are you considering staying in norway when you finish your degree/programme?

		Frequency	Percent	Valid Percent	Cumulative Percent
Valid	Yes	500	62,3	62,3	62,3
	No	302	37,7	37,7	100,0
	Total	802	100,0	100,0	

Variable 2

Gender

		Frequency	Percent	Valid Percent	Cumulative Percent
Valid	Female	393	49,0	49,0	49,0
	Male	409	51,0	51,0	100,0
	Total	802	100,0	100,0	

Krysstabell

Are you considering staying in norway when you finish your degree/programme? * Gender Crosstabulation

			Gender		
			Female	Male	Total
Are you considering staying in norway when you finish your degree/programme?	Yes	Count	260	240	500
		% within Gender	66,2%	58,7%	62,3%
	No	Count	133	169	302
		% within Gender	33,8%	41,3%	37,7%
Total		Count	393	409	802
		% within Gender	100,0%	100,0%	100,0%

Marginalfordelingene

Krysstabler

Are you considering staying in norway when you finish your degree/programme? * Gender Crosstabulation

			Gender		
			Female	Male	Total
Are you considering staying in norway when you finish your degree/programme?	Yes	Count	260	240	500
		% within Gender	66,2%	58,7%	62,3%
	No	Count	133	169	302
		% within Gender	33,8%	41,3%	37,7%
Total	Count		393	409	802
	% within Gender		100,0%	100,0%	100,0%

Prosentuer



Sammenlign

Begrensninger av krysstabeller

- Blir fort svært store/ mange
 - Ved flere svaralternativer
 - (f.eks. inntekt, høyde, alder)
 - Ved flere variabler
- Vanskelig å få oversikt

Table 4. Cross tabulation scores by gender and age group and frequency distributions of responses to Q8L7 of Swedish respondents in 2013, showing number (percentage) who selected each response.

Age	Gender	Strongly agree		Agree		Somewhat agree		Somewhat disagree		Disagree		Strongly disagree		Total	
20s	Men	7	(7.0)	20	(20.0)	32	(32.0)	21	(21.0)	13	(13.0)	7	(7.0)	100	(100.0)
	Women	15	(14.6)	36	(35.0)	24	(23.3)	15	(14.6)	10	(9.7)	3	(2.9)	103	(100.0)
	Both	22	(10.8)	56	(27.6)	56	(27.6)	36	(17.7)	23	(11.3)	10	(4.9)	203	(100.0)
30s	Men	8	(7.9)	21	(20.8)	37	(36.6)	13	(12.9)	12	(11.9)	10	(9.9)	101	(100.0)
	Women	13	(12.4)	26	(24.8)	35	(33.3)	21	(20.0)	7	(6.7)	3	(2.9)	105	(100.0)
	Both	21	(10.2)	47	(22.8)	72	(35.0)	34	(16.5)	19	(9.2)	13	(6.3)	206	(100.0)
40s	Men	3	(2.9)	26	(25.2)	28	(27.2)	22	(21.4)	23	(22.3)	11	(10.7)	103	(100.0)
	Women	9	(8.3)	22	(20.4)	29	(26.9)	22	(20.4)	23	(21.3)	3	(2.8)	108	(100.0)
	Both	12	(5.7)	38	(18.0)	57	(27.0)	44	(20.9)	46	(21.8)	14	(6.6)	211	(100.0)
50s	Men	4	(3.9)	10	(9.7)	25	(24.3)	19	(18.4)	33	(32.0)	12	(11.7)	103	(100.0)
	Women	6	(5.5)	18	(16.4)	32	(29.1)	23	(20.9)	22	(20.0)	9	(8.2)	110	(100.0)
	Both	10	(4.7)	28	(13.1)	57	(26.8)	42	(19.7)	55	(25.8)	21	(9.9)	213	(100.0)
60s	Men	0	0.0	5	(4.5)	32	(29.1)	26	(23.6)	37	(33.6)	10	(9.1)	110	(100.0)
	Women	7	(6.6)	14	(13.2)	43	(40.6)	15	(14.2)	23	(21.7)	4	(3.8)	106	(100.0)
	Both	7	(3.2)	19	(8.8)	75	(34.7)	41	(19.0)	60	(27.8)	14	(6.5)	216	(100.0)
Total	Men	22	(4.3)	72	(13.9)	154	(29.8)	101	(19.5)	118	(22.8)	50	(9.7)	517	(100.0)
	Women	50	(9.4)	116	(21.8)	163	(30.6)	96	(18.0)	85	(16.0)	22	(4.1)	532	(100.0)
	Both	72	(6.9)	188	(17.9)	317	(30.2)	197	(18.8)	203	(19.4)	72	(6.9)	1049	(100.0)

Table 5. Cross tabulation scores by gender and age group and frequency distributions of responses to Q8L10 of Swedish respondents in 2013, showing number (percentage) who selected each response.


Age	Gender	Strongly agree		Agree		Somewhat agree		Somewhat disagree		Disagree		Strongly disagree		Total	
20s	Men	6	(6.0)	15	(15.0)	30	(30.0)	29	(29.0)	17	(17.0)	3	(3.0)	100	(100.0)
	Women	12	(11.7)	19	(18.4)	41	(39.8)	17	(16.5)	12	(11.7)	2	(1.9)	103	(100.0)
	Both	18	(8.9)	34	(16.7)	71	(35.0)	46	(22.7)	29	(14.3)	5	(2.5)	203	(100.0)
30s	Men	10	(9.9)	12	(11.9)	29	(28.7)	23	(22.8)	18	(17.8)	9	(8.9)	101	(100.0)
	Women	13	(12.4)	18	(17.1)	31	(29.5)	23	(21.9)	16	(15.2)	4	(3.8)	105	(100.0)
	Both	23	(11.2)	30	(14.6)	60	(29.1)	46	(22.3)	34	(16.5)	13	(6.3)	206	(100.0)
40s	Men	4	(3.9)	8	(7.8)	30	(29.1)	24	(23.3)	26	(25.2)	11	(10.7)	103	(100.0)
	Women	6	(5.6)	19	(17.6)	38	(35.2)	26	(24.1)	13	(12.0)	6	(5.6)	108	(100.0)
	Both	10	(4.7)	27	(12.8)	68	(32.2)	50	(23.7)	39	(18.5)	17	(8.1)	211	(100.0)
50s	Men	4	(3.9)	5	(4.9)	18	(17.5)	31	(30.1)	30	(29.1)	15	(14.6)	103	(100.0)
	Women	7	(6.4)	13	(11.8)	33	(30.0)	20	(18.2)	27	(24.5)	10	(9.1)	110	(100.0)
	Both	11	(5.2)	18	(8.5)	51	(23.9)	51	(23.9)	57	(26.8)	25	(11.7)	213	(100.0)
60s	Men	1	(0.9)	4	(3.6)	29	(26.4)	25	(22.7)	38	(34.5)	13	(11.8)	110	(100.0)
	Women	3	(2.8)	14	(13.2)	28	(26.4)	27	(25.5)	26	(24.5)	8	(7.5)	106	(100.0)
	Both	4	(1.9)	18	(8.3)	57	(26.4)	52	(24.1)	64	(29.6)	21	(9.7)	216	(100.0)
Total	Men	25	(4.8)	44	(8.5)	136	(26.3)	132	(25.5)	129	(25.0)	51	(9.9)	517	(100.0)
	Women	41	(7.7)	83	(15.6)	171	(32.1)	113	(21.2)	94	(17.7)	30	(5.6)	532	(100.0)
	Both	66	(6.3)	127	(12.1)	307	(29.3)	245	(23.4)	223	(21.3)	81	(7.7)	1049	(100.0)

Bivariat analyse – oversikt


- Krysstabeller
- Spredningsplott
- Statistiske mål på samvariasjon
 - Phi
 - Pearsons r (produktmomentkorrelasjonskoeffisienten)
 - Gamma
 - Kendall Tau
 - Rho (rangkorrelasjonskoeffisienten)

Spredingsplot – visualiser samvariasjon

- Hver observasjon (respondent) er plottet i grafen
 - (dette er tiltenkt data!)



Figur 14.11 Spredningsdiagram som viser en **positiv** samvariasjon mellom variablene alder og antall fraværsdager siste år (• = én respondent, N = 25).



Figur 14.12 Spredningsdiagram som viser en **negativ** samvariasjon mellom variablene alder og antall sykefraværsdager siste år (• = én respondent, N = 25).

Raskt måte å få oversikt over trender..

K. Hayase


Table 4. Cross tabulation scores by gender and age group and frequency distributions of responses to Q8L7 of Swedish respondents in 2013, showing number (percentage) who selected each response.

Age	Gender	Strongly agree	Agree	Somewhat agree	Somewhat disagree	Disagree	Strongly disagree	Total
20s	Men	7 (7.0)	20 (20.0)	32 (32.0)	21 (21.0)	13 (13.0)	7 (7.0)	100 (100.0)
	Women	15 (14.6)	36 (35.0)	24 (23.3)	15 (14.6)	10 (9.7)	3 (2.9)	103 (100.0)
	Both	22 (10.8)	56 (27.6)	56 (27.6)	36 (17.7)	23 (11.3)	10 (4.9)	203 (100.0)
30s	Men	8 (7.9)	21 (20.8)	37 (36.6)	13 (12.9)	12 (11.9)	10 (9.9)	101 (100.0)
	Women	13 (12.4)	26 (24.8)	35 (33.3)	21 (20.0)	7 (6.7)	3 (2.9)	105 (100.0)
	Both	21 (10.2)	47 (22.8)	72 (35.0)	34 (16.5)	19 (9.2)	13 (6.3)	206 (100.0)
40s	Men	3 (2.9)	26 (25.2)	28 (27.2)	22 (21.4)	23 (22.3)	11 (10.7)	103 (100.0)
	Women	9 (8.3)	22 (20.4)	29 (26.9)	22 (20.4)	23 (21.3)	3 (2.8)	108 (100.0)
	Both	12 (5.7)	38 (18.0)	57 (27.0)	44 (20.9)	46 (21.8)	14 (6.6)	211 (100.0)
50s	Men	4 (3.9)	10 (9.7)	25 (24.3)	19 (18.4)	33 (32.0)	12 (11.7)	103 (100.0)
	Women	6 (5.5)	18 (16.4)	32 (29.1)	23 (20.9)	22 (20.0)	9 (8.2)	110 (100.0)
	Both	10 (4.7)	28 (13.1)	57 (26.8)	42 (19.7)	55 (25.8)	21 (9.9)	213 (100.0)
60s	Men	0 (0.0)	5 (4.5)	32 (29.1)	26 (23.6)	37 (33.6)	10 (9.1)	110 (100.0)
	Women	7 (6.6)	14 (13.2)	43 (40.6)	15 (14.2)	23 (21.7)	4 (3.8)	106 (100.0)
	Both	7 (3.2)	19 (8.8)	75 (34.7)	41 (19.0)	60 (27.8)	14 (6.5)	216 (100.0)
Total	Men	22 (4.3)	72 (13.9)	154 (29.8)	101 (19.5)	118 (22.8)	50 (9.7)	517 (100.0)
	Women	50 (9.4)	116 (21.8)	163 (30.6)	96 (18.0)	85 (16.0)	22 (4.1)	532 (100.0)
	Both	72 (6.9)	188 (17.9)	317 (30.2)	197 (18.8)	203 (19.4)	72 (6.9)	1049 (100.0)

Table 5. Cross tabulation scores by gender and age group and frequency distributions of responses to Q8L10 of Swedish respondents in 2013, showing number (percentage) who selected each response.

Age	Gender	Strongly agree	Agree	Somewhat agree	Somewhat disagree	Disagree	Strongly disagree	Total
20s	Men	6 (6.0)	15 (15.0)	30 (30.0)	29 (29.0)	17 (17.0)	3 (3.0)	100 (100.0)
	Women	12 (11.7)	19 (18.4)	41 (39.8)	17 (16.5)	12 (11.7)	2 (1.9)	103 (100.0)
	Both	18 (8.9)	34 (16.7)	71 (35.0)	46 (22.7)	29 (14.3)	5 (2.5)	203 (100.0)
30s	Men	10 (9.9)	12 (11.9)	29 (28.7)	23 (22.8)	18 (17.8)	9 (8.9)	101 (100.0)
	Women	13 (12.4)	18 (17.1)	31 (29.5)	23 (21.9)	16 (15.2)	4 (3.8)	105 (100.0)
	Both	23 (11.2)	30 (14.6)	60 (29.1)	46 (22.3)	34 (16.5)	13 (6.3)	206 (100.0)
40s	Men	4 (3.9)	8 (7.8)	30 (29.1)	24 (23.3)	26 (25.2)	11 (10.7)	103 (100.0)
	Women	6 (5.6)	19 (17.6)	38 (35.2)	26 (24.1)	13 (12.0)	6 (5.6)	108 (100.0)
	Both	10 (4.7)	27 (12.8)	68 (32.2)	50 (23.7)	39 (18.5)	17 (8.1)	211 (100.0)
50s	Men	4 (3.9)	5 (4.9)	18 (17.5)	31 (30.1)	30 (29.1)	15 (14.6)	103 (100.0)
	Women	7 (6.4)	13 (11.8)	33 (30.0)	20 (18.2)	27 (24.5)	10 (9.1)	110 (100.0)
	Both	11 (5.2)	18 (8.5)	51 (23.9)	51 (23.9)	57 (26.8)	25 (11.7)	213 (100.0)
60s	Men	1 (0.9)	4 (3.6)	29 (26.4)	25 (22.7)	38 (34.5)	13 (11.8)	110 (100.0)
	Women	3 (2.8)	14 (13.2)	28 (26.4)	27 (25.5)	26 (24.5)	8 (7.5)	106 (100.0)
	Both	4 (1.9)	18 (8.3)	57 (26.4)	52 (24.1)	64 (29.6)	21 (9.7)	216 (100.0)
Total	Men	25 (4.8)	44 (8.5)	136 (26.3)	132 (25.5)	129 (25.0)	51 (9.9)	517 (100.0)
	Women	41 (7.7)	83 (15.6)	171 (32.1)	113 (21.2)	94 (17.7)	30 (5.6)	532 (100.0)
	Both	66 (6.3)	127 (12.1)	307 (29.3)	245 (23.4)	223 (21.3)	81 (7.7)	1049 (100.0)

Percentage of 'Strongly Agree' Responses by Gender and Age Group in Table 9



Bivariat analyse – oversikt

- Krysstabeller
- Spredningsplott
- Statistiske mål på samvariasjon
 - Phi
 - Pearsons r (produktmomentkorrelasjonskoeffisienten)
 - Gamma
 - Kendall Tau
 - Rho (rangkorrelasjonskoeffisienten)

Statistiske mål på samvariasjon


- Phi
- Pearsons r (produktmomentkorrelasjonskoeffisienten)
- Gamma
- Kendall Tau
- Rho (rangkorrelasjonskoeffisienten)

Statistiske mål på samvariasjon (**korrelasjon**)


- Karakteristika av målene:
 - Varierer fra -1 til +1.
 - Korrelasjon på 0 betyr at det ikke er noe systematisk samvariasjon
 - Korrelasjon på -1 betyr at samvariasjonen er invers/negativ: når en går opp, går den andre ned
 - Korrelasjon på 1 betyr at samvariasjonen er positiv, at når en går opp, går den andre også opp
 - Jo høyere absolutt korrelasjon (pluss eller minus) jo sterkere er samvariasjonen
- Styrken på korrelasjonen
 - Ingen fasit, avhengig av fenomenet som vi studerer, og hvilke forventninger vi har.
 - Tommelfingerregler (positive og negative verdier):
 - $< 0,30$ = svak korrelasjon
 - $0,30 - 0,49$ = middels korrelasjon
 - $\geq 0,50$ = sterk korrelasjon
 - Husk at studiedesign kan påvirke korrelasjon!
 - Common Method Variance (CMV).

Spredingsplot – visualiser samvariasjon

- Figur 14.11 vil ha høy **positiv** korrelasjon (ca. 0.80)
- Figur 14.12 vil ha høy **negativ** korrelasjon (ca. -0.80)



Figur 14.11 Spredningsdiagram som viser en positiv samvariasjon mellom variablene alder og antall fraværsdager siste år (• = én respondent, N = 25).




Figur 14.12 Spredningsdiagram som viser en negativ samvariasjon mellom variablene alder og antall sykefraværsdager siste år (• = én respondent, N = 25).

Statistiske mål på samvariasjon (korrelasjon)

- Vanlige statistiske mål på samvariasjon
 - Pearsons r (produktmomentkorrelasjonskoeffisienten)
 - Brukt for metrisk data (contineous), som er normalfordelt
 - Phi
 - Tilsvarende Pearsons r , men for binær data (ja/nei)
 - Kendall Tau
 - Mest brukt for ordinal data, og ikke normalfordelt metrisk data, og når det er noe par-data
 - Bedre i mindre datasett
 - Rho (rangkorrelasjonskoeffisienten)
 - Mest brukt for ordinal data , og ikke normalfordelt metrisk data
 - Bedre i større datasett
 - Gamma
 - Brukt for ordinal data, der det ikke er par-data

Korrelasjon på 0

- En korrelasjon på 0 *kan* bety at det ikke er en sammenheng
 - Dersom det er uventet, verdt å undersøke!




Figur 14.14 Spredningsdiagram som viser en ikke-lineær samvariasjon mellom stressnivå (målt på en skala fra 1 til 10) og prestasjoner på jobben (målt på en skala fra 1 til 6). Hver prikk representerer en respondent.

Eksempel på utregning

→ Ekstra material, for de som lærer godt ved å forstå formuler

Eksempel på utregning av Pearson r

Obs.	Høyde	Vekt
1	164	51
2	167	56
3	170	51
4	171	62
5	166	54
6	169	56
7	168	56
8	171	59
9	168	57
10	168	54
Sum	1 682	556
Gj.snitt	168,2	55,6



Obs.	Høyde	$(X-\bar{X})$	$(X-\bar{X})^2$	Vekt	$(Y-\bar{Y})$	$(Y-\bar{Y})^2$	$(X-\bar{X}) \cdot (Y-\bar{Y})$
1	164	-4,2	17,6	51	-4,6	21,2	19,3
2	167	-1,2	1,4	56	0,4	0,2	-0,5
3	170	1,8	3,2	51	-4,6	21,2	-8,3
4	171	2,8	7,8	62	6,4	41,0	17,9
5	166	-2,2	4,8	54	-1,6	2,6	3,5
6	169	0,8	0,6	56	0,4	0,2	0,3
7	168	-0,2	0,0	56	0,4	0,2	-0,1
8	171	2,8	7,8	59	3,4	11,6	9,5
9	168	-0,2	0,0	57	1,4	2,0	-0,3
10	168	-0,2	0,0	54	-1,6	2,6	0,3
Sum	1 682	0	43,6	556	0	102,4	41,8
Gj.snitt	168,2			55,6			

Multipliserer avvikene

Kvadrerte avvik

Avvik fra gj.snittet

Obs.	Høyde	$(\bar{X} - X)$	$(X - \bar{X})^2$	Vekt	$(\bar{Y} - Y)$	$(\bar{Y} - Y)^2$	$(\bar{X} - X) * (\bar{Y} - Y)$
1	164	-4,2	17,6	51	-4,6	21,2	19,3
2	167	-1,2	1,4	56	0,4	0,2	-0,5
3	170	1,8	3,2	51	-4,6	21,2	-8,3
4	171	2,8	7,8	62	6,4	41,0	17,9
5	166	-2,2	4,8	54	-1,6	2,6	3,5
6	169	0,8	0,6	56	0,4	0,2	0,3
7	168	-0,2	0,0	56	0,4	0,2	-0,1
8	171	2,8	7,8	59	3,4	11,6	9,5
9	168	-0,2	0,0	57	1,4	2,0	-0,3
10	168	-0,2	0,0	54	-1,6	2,6	0,3
Sum	1 682	0	43,6	556	0	102,4	41,8
Gj.snitt	168,2			55,6			

Standardavvik høyde: $S = \sqrt{\frac{1}{10-1} \sum (164 - 168,2)^2 + \dots + (168 - 168,2)^2} = 2,20$

Obs.	Høyde	$(\bar{X} - X)$	$(X - \bar{X})^2$	Vekt	$(\bar{Y} - Y)$	$(\bar{Y} - Y)^2$	$(\bar{X} - X) * (\bar{Y} - Y)$
1	164	-4,2	17,6	51	-4,6	21,2	19,3
2	167	-1,2	1,4	56	0,4	0,2	-0,5
3	170	1,8	3,2	51	-4,6	21,2	-8,3
4	171	2,8	7,8	62	6,4	41,0	17,9
5	166	-2,2	4,8	54	-1,6	2,6	3,5
6	169	0,8	0,6	56	0,4	0,2	0,3
7	168	-0,2	0,0	56	0,4	0,2	-0,1
8	171	2,8	7,8	59	3,4	11,6	9,5
9	168	-0,2	0,0	57	1,4	2,0	-0,3
10	168	-0,2	0,0	54	-1,6	2,6	0,3
Sum	1 682	0	43,6	556	0	102,4	41,8
Gj.snitt	168,2			55,6			

Standardavvik høyde: $S = \sqrt{\frac{1}{10-1} \sum (164 - 168,2)^2 + \dots + (168 - 168,2)^2} = 2,20$

Standardavvik vekt: $S = \sqrt{\frac{1}{10-1} \sum (51 - 55,6)^2 + \dots + (54 - 55,6)^2} = 3,37$

Obs.	Høyde	$(\bar{X}-X)$	$(X-\bar{X})^2$	Vekt	$(\bar{Y}-Y)$	$(Y-\bar{Y})^2$	$(\bar{X}-X)*(\bar{Y}-Y)$
1	164	-4,2	17,6	51	-4,6	21,2	19,3
2	167	-1,2	1,4	56	0,4	0,2	-0,5
3	170	1,8	3,2	51	-4,6	21,2	-8,3
4	171	2,8	7,8	62	6,4	41,0	17,9
5	166	-2,2	4,8	54	-1,6	2,6	3,5
6	169	0,8	0,6	56	0,4	0,2	0,3
7	168	-0,2	0,0	56	0,4	0,2	-0,1
8	171	2,8	7,8	59	3,4	11,6	9,5
9	168	-0,2	0,0	57	1,4	2,0	-0,3
10	168	-0,2	0,0	54	-1,6	2,6	0,3
Sum	1 682	0	43,6	556	0	102,4	41,8
Gj.snitt	168,2			55,6			

Standardavvik høyde: $S = \sqrt{\frac{1}{10-1} \sum (164 - 168,2)^2 + \dots + (168 - 168,2)^2} = 2,20$

Standardavvik vekt: $S = \sqrt{\frac{1}{10-1} \sum (51 - 55,6)^2 + \dots + (54 - 55,6)^2} = 3,37$

Kovarians: $Cov_{h\ddot{o}yde, vekt} = \frac{\sum_{i=1}^n (164-168,2)(51-55,6) + \dots + (168-168,2)(54-55,6)}{(10-1)} = 4,6444$

Obs.	Høyde	$(\bar{X}-X)$	$(X-\bar{X})^2$	Vekt	$(\bar{Y}-Y)$	$(\bar{Y}-Y)^2$	$(\bar{X}-X)*(\bar{Y}-Y)$
1	164	-4,2	17,6	51	-4,6	21,2	19,3
2	167	-1,2	1,4	56	0,4	0,2	-0,5
3	170	1,8	3,2	51	-4,6	21,2	-8,3
4	171	2,8	7,8	62	6,4	41,0	17,9
5	166	-2,2	4,8	54	-1,6	2,6	3,5
6	169	0,8	0,6	56	0,4	0,2	0,3
7	168	-0,2	0,0	56	0,4	0,2	-0,1
8	171	2,8	7,8	59	3,4	11,6	9,5
9	168	-0,2	0,0	57	1,4	2,0	-0,3
10	168	-0,2	0,0	54	-1,6	2,6	0,3
Sum	1 682	0	43,6	556	0	102,4	41,8
Gj.snitt	168,2			55,6			

Standardavvik høyde: $S = \sqrt{\frac{1}{10-1} \sum (164 - 168,2)^2 + \dots + (168 - 168,2)^2} = 2,20$

Standardavvik vekt: $S = \sqrt{\frac{1}{10-1} \sum (51 - 55,6)^2 + \dots + (54 - 55,6)^2} = 3,37$

Kovarians: $Cov_{høyde, vekt} = \frac{\sum_{i=1}^n (164-168,2)(51-55,6) + \dots + (168-168,2)(54-55,6)}{(10-1)} = 4,6444$

Pearsons r: $Corr_{høyde, vekt} = \frac{4,644}{2,20 * 3,37} = 0,626$

Slutningsstatistikk

Trekke **innsikt** fra statistiske resultater


Slutningsstatistikk

- Prinsipper for å kunne trekke slutninger om fordelinger i **populasjonen fra fordelinger i utvalg**, samt å spesifisere **usikkerheten**
 - Estimering
 - Hypotesetesting
 - Forutsetter sannsynlighetsutvalg (jf. forrige forelesning)

Estimering av populasjonsgjennomsnittet

- Tre fordelinger:
 - *Utvalgsfordelingen*
 - viser hvordan observasjonene i et foreliggende utvalg (dataen vår) fordeler seg på variabelen
 - *Samplingfordelingen*
 - viser hvordan en uendelig mengde **tenkte utvalg** vil fordele seg med hensyn til utvalgsgjennomsnittet
 - *Populasjonsfordelingen*
 - fordelingen av samtlige enheters verdier på variabelen

Estimering av populasjonsgjennomsnittet



Pearsons r

- Hvor sikre kan vi være på at en korrelasjon i utvalget også gjelder i populasjonen?
 - Eks.: Er det samvariasjon mellom politisk ståsted og i hvilken grad man føler et personlig ansvar for å prøve å redusere klimaendringene?

SPØR ALLE

B26 KORT 10 I politikken snakkes det iblant om venstresiden og høyresiden. Se på dette kortet, og plasser deg selv på en skala der 0 står for venstresiden og 10 står for høyresiden.


Venstre- siden										Høyre- siden	(Nekter)	(Vet ikke)
00	01	02	03	04	05	06	07	08	09	10	77	88

D23 KORT 40 I hvilken grad føler du et personlig ansvar for å prøve å redusere klimaendringene?

Ikke i det hele tatt										I en stor grad	(Nekter)	(Vet ikke)
00	01	02	03	04	05	06	07	08	09	10	77	88

D24 KORT 41 Hvor bekymret er du for klimaendringer?

Ikke bekymret i det hele tatt	1
Ikke særlig bekymret	2
Litt bekymret	3
Veldig bekymret	4
Ekstremt bekymret	5
(Nekter)	7
(Vet ikke)	8



Pearsons r

- Korrelasjonskoeffisienten er
 - forskjellig fra 0
 - Negativ
 - Signifikant
- Nullhypotesen om at det ikke er samvariasjonen mellom variablene i populasjonen forkastes
 - Hvilken vei går sammenhengen?
 - Se på skalaene på forrige side: hva vil det si å få høyere scor på hver skala?
 - Er korrelasjonen sterk?


Correlations

		Plassering på venstre- eller høyresiden	I hvilken grad føler du et personlig ansvar for å prøve å redusere klimaendringene?
Plassering på venstre- eller høyresiden	Pearson Correlation	1	-,156**
	Sig. (2-tailed)		<,001
	N	1497	1477
I hvilken grad føler du et personlig ansvar for å prøve å redusere klimaendringene?	Pearson Correlation	-,156**	1
	Sig. (2-tailed)	<,001	
	N	1477	1522

**. Correlation is significant at the 0.01 level (2-tailed).

Pearsons r

- Nullhypotesen om at det ikke er samvariasjonen mellom variablene i populasjonen forkastes
 - Hvilken vei går sammenhengen?
 - Er korrelasjonen sterk?



Correlations			
		Plassering på venstre- eller høyresiden	I hvilken grad føler du et personlig ansvar for å prøve å redusere klimaendringene?
Plassering på venstre- eller høyresiden	Pearson Correlation	1	-,156**
	Sig. (2-tailed)		<,001
	N	1497	1477
I hvilken grad føler du et personlig ansvar for å prøve å redusere klimaendringene?	Pearson Correlation	-,156**	1
	Sig. (2-tailed)	<,001	
	N	1477	1522


** . Correlation is significant at the 0.01 level (2-tailed).

Anbefaler å spille korrelasjonsspillet:
<https://www.guessthecorrelation.com/>

Feilmargin – hvert utvalg vil være noe forskjellig fra populasjonen

	TNS Gallup	MMI Univero	Valgresultat
AP	32,2	30,5	32,8
FrP	18,8	19,7	22,1
H	15,0	15,0	14,1
SV	10,0	10,9	8,7
KrF	7,5	7,8	6,8
SP	6,2	6,9	6,5
V	5,9	6,2	5,9
RV	1,8	1,9	1,2
Antall velgere	3 183	3 780	2 602 564

$$SE(\hat{p}) = \sqrt{\frac{\hat{p}(100 - \hat{p})}{N}}$$



Resultater fra to utvalgsundersøkelser (estimat) og valg-resultat (i populasjonen) ved stortingsvalget i 2005 (prosent)

Hypotese og hypotesetesting

- **Hypotese:** En påstand om egenskaper i den ukjente populasjonen
- **Hypotesetest:** bruke informasjon fra utvalg for å vurdere evidens for støtte av hypotesen.
 - H_0 : Det er ikke er noen forskjell mellom det som undersøkes i populasjonen.
 - Det vil si: Forskjeller observert i utvalget er rent tilfeldig
 - H_1 : Det er en forskjell i populasjonen
 - Forskjeller som er observert er ikke tilfeldig
- Merk: hypoteser er alltid påstander om populasjon, basert på analyse av utvalg.

Eksempel – prosessen

**1. Vi starter med noen spørsmål om muligheten til å komme seg frem her i verden.
Hvor viktig mener du følgende forhold er for å komme seg frem i verden?**

Sett ett kryss for hver linje

	Helt avgjørende	Svært viktig	Ganske viktig	Ikke særlig viktig	Ikke viktig i det hele tatt	Vet ikke
At en kommer fra en velstående familie?	☐	☐	☐	☐	☐	☐
At ens foreldre har god utdanning?	☐	☐	☐	☐	☐	☐
At en selv har god utdanning?	☐	☐	☐	☐	☐	☐
Hardt arbeid?	☐	☐	☐	☐	☐	☐

2. Og hvor viktig mener du følgende forhold er?

Sett ett kryss for hver linje

	Helt avgjørende	Svært viktig	Ganske viktig	Ikke særlig viktig	Ikke viktig i det hele tatt	Vet ikke
At en kjenner de rette personene?	☐	☐	☐	☐	☐	☐
At en har politiske forbindelser?	☐	☐	☐	☐	☐	☐
Å gi bestikkelser?	☐	☐	☐	☐	☐	☐
Etnisk bakgrunn, uttrykt f.eks. ved kultur, hudfarge og liknende	☐	☐	☐	☐	☐	☐
Religion?	☐	☐	☐	☐	☐	☐
Om en er født mann eller kvinne?	☐	☐	☐	☐	☐	☐

Hypotesetesting: t-test

- t-test: brukes for å sammenlikne gjennomsnitt av to variabler.
 - Er det sannsynlig at en observert forskjell også er tilstede i populasjonen?
(statistisk signifikant forskjellig)

2. Og hvor viktig mener du følgende forhold er?

Sett ett kryss for hver linje

	Helt avgjørende	Svært viktig	Ganske viktig	Ikke særlig viktig	Ikke viktig i det hele tatt	Vet ikke
At en kjenner de rette personene?	☐	☐	☐	☐	☐	☐
At en har politiske forbindelser?	☐	☐	☐	☐	☐	☐
Å gi bestikkelser?	☐	☐	☐	☐	☐	☐
Etnisk bakgrunn, uttrykt f.eks. ved kultur, hudfarge og liknende	☐	☐	☐	☐	☐	☐
Religion?	☐	☐	☐	☐	☐	☐
Om en er født mann eller kvinne?	☐	☐	☐	☐	☐	☐

H_0 : Det er ingen forskjell mellom menn og kvinner mht hvor viktig man mener at kjønn er for muligheten for å komme seg frem i livet.

H_1 : Det er forskjell mellom menn og kvinner mht hvor viktig man mener at kjønn er for muligheten for å komme seg frem i livet.

Hypotesetesting: t-test (steg 1)

- Hypotesetesting
 - Sett opp nullhypotesen
 - H_0 : Det er ingen forskjell mellom gjennomsnittene for menn og kvinner i populasjonen, for hvor viktig man mener at kjønn er for muligheten for å komme seg frem i livet
 - H_1 : Det er en forskjell mellom gjennomsnittene for menn og kvinner i populasjonen, for hvor viktig man mener at kjønn er for muligheten for å komme seg frem i livet
 - Merk her: vi har ikke sagt om snitte er høyere eller lavere for menn enn kvinner, KUN at den er forskjellig

Notater fra dataen (resultater fra SPSS)

2. Og hvor viktig mener du følgende forhold er?

Sett ett kryss for hver linje

	Helt avgjørende	Svært viktig	Ganske viktig	Ikke særlig viktig	Ikke viktig i det hele tatt	Vet ikke
At en kjenner de rette personene?	☐	☐	☐	☐	☐	☐
At en har politiske forbindelser?	☐	☐	☐	☐	☐	☐
Å gi bestikkelser?	☐	☐	☐	☐	☐	☐
Etnisk bakgrunn, uttrykt f.eks. ved kultur, hudfarge og liknende	☐	☐	☐	☐	☐	☐
Religion?	☐	☐	☐	☐	☐	☐
Om en er født mann eller kvinne?	☐	☐	☐	☐	☐	☐

Value Labels:

Value	Label
1	Helt avgjørende
2	Svært viktig
3	Ganske viktig
4	Ikke særlig viktig
5	Ikke viktig i det hele tatt
8	Vet ikke

Satt til missing

Case Processing Summary

	Included		Cases Excluded		Total	
	N	Percent	N	Percent	N	Percent
Kjønn viktig for å komme seg fram * Kjønn	1289	97,4%	34	2,6%	1323	100,0%

Report

Kjønn viktig for å komme seg fram				
Kjønn	Mean	N	Std. Deviation	
Mann	4,21	593	1,166	
Kvinne	3,81	696	1,199	
Total	3,99	1289	1,201	

- Nullhypotese: Differansen er 0
- Observert differanse: 0,40
 - 4,21 (mann) minus 3,81(kvinne) = 0.40
- Er differansen så stor at det er sannsynlig at det også er forskjeller mellom kjønnene i populasjonen, eller er forskjellene bare et utslag av tilfeldige utvalg?

T-test: velg signifikansnivå (steg 2)

- Signifikansnivå (0.1, 0.05 eller 0,001) påvirker risiko for Type I og type II feil

Type I og type II feil (MERK: nullhypotesen er at det ikke er en forskjell)

		Nullhypotesen	
		Sann	Uriktig
Vår konklusjon	Forkaster	Feil (type I)	Korrekt
	Aksepterer	Korrekt	Feil (type II)

Type I og type II feil (MERK: nullhypotesen er at det ikke er en forskjell)

		Nullhypotesen er:	
		Sann	Uriktig
Vår konklusjon (fra analysen)	Forkaster	 False positive (Type I error) You're pregnant	 True negative You're not pregnant
	Aksepterer	 True positive You're pregnant	 False negative (Type II error) You're not pregnant

T-test: velg signifikansnivå ad Type I og type II feil

- Avhengighetsforhold mellom feiltypene:
 - Jo lavere signifikansnivå:
 - Jo mindre sjanse for type I feil
 - Jo større sjanse for type II feil
 - Forholdet kommer an på: størrelse på utvalg, effektstørrelse og signifikansnivå
 - Å bruke 1 prosents (0.01) signifikansnivå i stedet for 5 (0,05) prosents vil dermed øke risikoen for å begå feil av type II,
 - dvs. at det blir mer sannsynlig at vi beholder nullhypoteser som ikke er korrekte.
 - Mest vanlig å velge 1 prosent (0,01), (eller 0.1 prosent (0,001), gitt store datasett)
 - For å avgjøre rett nivå: gjør en «power analysis»

Finn korrekt antall frihetsgrader (steg 3)

- Antall frihetsgrader kommer an på testen. F.eks.
 - One sample t-test: $n-1$
 - Uavhengig utvalg, sammenlikne snitt: n_1+n_2-2
 - Antar lik varians

Beregn t-verdi (**steg 4**)

- Bruk statistisk programvare
 - SPSS, Python, R, STATA etc.
- Eller regn ut:

$$t = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$$

- Sammenlikn t-verdi med kritisk verdi (t-fordelingen)
 - Statistisk programvare gjør dette også.
- Konkluder og identifiser implikasjoner

Beregn t-verdi (steg 4)

- Bruk statistisk programvare
 - SPSS, Python, R, STATA etc.

Case Processing Summary

	Included		Cases Excluded		Total	
	N	Percent	N	Percent	N	Percent
Kjønn viktig for å komme seg fram * Kjønn	1289	97,4%	34	2,6%	1323	100,0%

Report

Kjønn viktig for å komme seg fram

Kjønn	Mean	N	Std. Deviation
Mann	4,21	593	1,166
Kvinne	3,81	696	1,199
Total	3,99	1289	1,201

- Resultat fra t-test:
 - **t-statistic:** 6.046
 - **p-value:** approximately 1.95×10^{-9}
 - Konklusjon: Det er en statistisk signifikant forskjell mellom kjønnene, i den grad de ser kjønn som en faktor.

Kjikvadrat-test

- test for statistisk samvariasjon for **kategori-/nominalvariable**

- Tilsvarende prosess som for t-test
 - Beregnet *kji*-kvadratverdi
 - Sammenlikner med kritisk verdi i *kji-kvadrat*-fordelingen
- Eksempel:
 - Er det forskjeller mellom kvinnelige og mannlige internasjonale studenter mht om de planlegger å bli i Norge etter avsluttede studier?
 - Se tabell 15.17 for signifikansnivå og frihetsgrader

Variansanalyse (ANOVA)

(Alternative til t-test:

Når det **er flere enn 2** grupper /gjennomsnitt)


Variansanalyse (ANOVA)

(Alternative til t-test, når det er flere enn 2 grupper /snitt)

- Målenivå:
 - Avhengig variabel på metrisk nivå (men ordinal brukes også)
 - Uavhengig variabel nominalnivå (gruppe)
 - Brukes når den uavhengige variabelen har mer enn to grupper
- Eksperimenter
- Sammenligne forskjeller mellom undersøkelsesgrupper i en spørreundersøkelse:
 - Variansanalyse deler totalvariasjonen i varians innen gruppen («innengruppevariens») og varians mellom gruppene («mellomgruppevariens»).
 - tester om gjennomsnittet av variansen mellom gruppene er større enn variansen innen gruppene.

→ tester om gjennomsnittet av variansen mellom gruppene er større enn variansen innen gruppene.

- Merk:
 - Det er varians innen hver gruppe (by)
 - Er den større eller mindre enn mellom gruppene (byer)



Variansanalyse (ANOVA)


(Alternative til t-test, men når det er flere enn 2 grupper /snitt)

- Eksempler på bruk:
 - Reklame kampanje, kjørt på Instagram, TikTok, Facebook og Snap
 - Bruk av insentiver på jobb: gruppebonus, individuell bonus, gavekort, ingenting
 - Resultat av tre investeringsstrategier
 - Karaktergjennomsnitt på campus: Trondheim, Gjøvik og Ålesund
 - ...

Variansanalyse (ANOVA) **Eksempel**

(Alternative til t-test, men når det er flere enn 2 grupper /snitt)

- Karaktergjennomsnitt på campus: Trondheim, Gjøvik og Ålesund
 - Nullhypotese: det er ingen forskjell i snitt
 - Variansanalyse deler totalvariasjonen i varians innen gruppen («innengruppevarians») og varians mellom gruppene («mellomgruppevarians»).
- tester om gjennomsnittet av variansen mellom gruppene er større enn variansen innen gruppene.



Karakter	Ålesund	Trondheim	Gjøvik
A	13	24	21
B	31	105	21
C	49	129	34
D	25	78	24
E	8	17	7
F	5	15	9
(n)	131	368	116
Mean	3.008	2.989	2.983

Variansanalyse (ANOVA)

(Alternative til t-test, men når det er flere enn 2 grupper /snitt)

- Eksempler på bruk:

- Karaktergjennomsnitt på campus: Trondheim, Gjøvik og Ålesund
- Nullhypotese: det er ingen forskjell i snitt
 - Konverterer bokstavkarakter til tall
- Gjennomsnitt:
 - Ålesund: 3.008
 - Trondheim: 2.989
 - Gjøvik: 2.983
- F-Statistic: 0.0152
- p-Value: 0.985

Karakter	Ålesund	Trondheim	Gjøvik
A	13	24	21
B	31	105	21
C	49	129	34
D	25	78	24
E	8	17	7
F	5	15	9
(n)	131	368	116

- Konklusjon: null hypotesen kan ikke forkastes → ingen evidens for at det er forskjell på snittene

Variansanalyse (eks. Iversen & Norpoth)

- «The **control group** will be shown an economy-less newscast, **treatment group A** will be shown the same newscast plus a story on unemployment, **group B** one on inflation instead, **group C** one on the deficit; and **group D** one on foreign trade»
- Dependent variable: an evaluation of the importance of the economy on a ten-point scale
- Do the massmedia affect the salience of each of those four economic issues equally

Respondent						
	1	2	3	4	5	Gj.snitt
Unemployment story	6	6	6	8	9	7,0
Inflation story	7	8	8	8	9	8,0
Deficit story	4	4	5	6	6	5,0
Foreign trade story	5	5	6	6	8	6,0
No economic story	3	4	4	4	5	4,0
Gjennomsnitt alle observasjoner: 6,0						

Variansanalyse (eks. Iversen & Norpoth)

- TSS = total sum of squares (summen av kvadrerte avvik fra gjennomsnittsverdien)
- BSS = between-group sum of squares (effekten av gruppetilhørighet, det modellen forklarer)
- RSS = residual/within-group sum of squares (effekten av andre variabler, det modellen ikke forklarer)

ANOVA-tabellen

- Er forskjellene signifikante? Avhenger av:
 - Forskjellen i gjennomsnittet
 - Standardavviket i hver gruppe
 - Utvalgsstørrelsen

economy

	Sum of Squares	df	Mean Square	F	Sig.
Between Groups	50,000	4	12,500	11,364	<,001
Within Groups	22,000	20	1,100		
Total	72,000	24			

- De er signifikante
 - Vet ikke om alle er forskjellige, eller hvilke som er forskjellige