

Kvantitative og kvalitative metoder


Kvantitative undersøkelse – Regresjonsanalyse

- Bivariat regresjonsanalyse
- Multippel regresjonsanalyse
- Forutsetninger for regresjonsanalyse

Se bokkapitler på BB

- Johannessen A., Christoffersen L., Tufte P.A. (2020)
- Ringdal (2018)

Njål Andersen



Regresjonsanalyse- oversikt

Hvordan gjennomsnittsverdien på en **avhengig** variabel (Y) varierer med en eller flere **uavhengige** variabler (X)

- [antar en] Lineær sammenheng mellom Y og X-variablene
 - (men dette kan håndteres på ulikt vis)
- Enkel (bivariat) og multippel regresjonsanalyse
- Avhengig variabel **metrisk** målenivå
 - (men også *ordinalvariabler* med mange kategorier benyttes)
- Uavhengig variabel: Alle typer variabler
 - (nominalvariabler(kategoriske) må kodes som **dummy-variabler**)

Korrelasjon vs. Regresjon

Korrelasjon

- Viser samvariasjonen mellom to eller flere variabler
- Pearsons r varierer mellom -1 og 1, og avklarer styrken og retningen for lineære sammenhenger

Eksempel:

- Det er samvariasjon/sammenheng mellom tidsbruken i metodefaget og oppnådd karakter.

Regresjon

- Kausal sammenheng mellom variabler
 - (merk: for «kausaltet» kreves at alle antakelser for det blir møtt)
- En avhengig variabel blir forklart ut ifra en eller flere uavhengige variabler

Eksempel:

- Hvis tidsbruken økes med 1 enhet $\rightarrow$ øker karakteren med 0.1 enhet (fra C mot B)
- Hvis tidsbruken faller med 1 enhet $\rightarrow$ faller karakteren med 0.1 enhet (fra A mot B)
 - Det vil også si at om tidsbruk øker med 10 enheter, endrer karakterer seg med 1 hel enhet)

Korrelasjon

Samvariasjon, vet ikke noe om hva som påvirker hva.

- X kan påvirke Y
- Y kan påvirke X
- Y og X kan påvirkes av Z (ikke inkludert i analysen)

Eksempel:

- Pearsons korrelasjon=0.5 mellom Kaffe og Lykke
- Usikkert om man drikker kaffe når man er glad
- Er glad når man drikker kaffe
- Blir påvirket av god stemning i lokalet



Regresjon

Kausal sammenheng, skal måle hva som påvirker avhengig variabel.

- X skal påvirke Y
- Y skal ikke påvirke X
- Y kan påvirkes av Z (som er inkludert i analysen, eller ikke)
- Z skal ikke påvirke X (dersom z er inkludert i analysen)

Eksempel:

- Regresjons koeffisient=0.5 .
- Kaffe påvirker Lykke, der en kaffe øker lykke med 0.5



Bivariat regresjonsanalyse (to variabler)

$$Y = a + bX_i + e$$

Avhengig variabel (kjent)
Denne variabelen som problemstillingen handler om (eks. Lykke)


Konstantledd (ukjent)

Koeffisient (ukjent)
Dette er det vi er interessert i.
Størrelse på effekten.
Vi kjører regresjon for å beregne denne.
(eks. hvor mye kaffe påvirker lykke)

Restledd (det vi ikke forklarer)
Andre **ukjente** faktorer (variabler) – denne kan vi ikke beregne, men kan benyttes til å teste **forutsetningene**

Uavhengigvariabel / forklaringsvariabel (kjent)
(eks. Kaffe)

Bivariat regresjonsanalyse (enkel regresjon)



Ordinary Least Squares (**OLS**) eller Minste Kvadraters Metode (**MKM**) på norsk

- Vi benytter OLS metoden til å estimere (bergene) **a** og **b**

Matematiskmodell vs. regresjonsmodell

$$Y = X_1 + X_2$$
$$6 = 2 + 4$$

$$Y = a + bX_1 + cX_2 + e$$
$$22 = 15 + b(8) + c(30) + e$$

Vi kjører regresjon og finner at:

$$b = 0,4$$

$$c = 0,1$$

$$22 = 15 + 0,4(8) + 0,1(30) + e$$

$$22 - 21,2 = 0,8 = e$$

b og c kalles regresjonskoeffisienter og forteller oss hvor mye X1 og X2 påvirker Y.

$$\text{Lykke} = 10 + 0.5 \cdot \text{kafe} + 0.2 \cdot \text{stemning} + e$$

(merk, 10, er konstant $\rightarrow$ grunn lykken man har. Lykke starter ikke på 0 😊)

Forutsetninger for OLS

- I. Regresjonsmodellen er lineær, er korrekt spesifisert og har et additivt feilledd.
- II. Feilleddet har et populasjonsgjennomsnitt lik null, **normalfordelt**.
- III. Alle forklaringsvariablene er ukorrelerte med feilleddet.
- IV. Feilleddet har konstant varians, dvs. ingen **heteroskedastisitet**.
- V. Ingen av forklaringsvariablene er en perfekt funksjon av noen av de andre forklaringsvariablene, dvs. ingen **multikollinearitet**.
- VI. Tilfeldig utvalg
- VII. De uavhengige variablene skal ikke være konstante

$$Y = a + bX_i + e$$

Bivariat regresjonsanalyse

Ønsker å undersøke om en variabel (avhengig) kan forklares ut fra **en** annen (uavhengig) variabel

- Til hvilken grad blir karakter i metodefaget påvirket av antall ganger man stiller til forelesning?



$$Y = a + b X_i + e$$


$$\text{Karakter} = a + b (\text{Forelesning}) + e$$

$$H_0: \beta_i = 0 ; H_1: \beta_i \neq 0 \text{ (to-veis test)}$$

Enkel regresjonsanalyse


- Skiller mellom populasjon og utvalg
 - (mao data fra utvalgsundersøkelse hvor det er foretatt et sannsynlighetsutvalg)
- Legger til grunn en lineær sammenheng mellom variablene en avhengig variabel (Y) og en uavhengig variabel (X)
 - (eks. boligpris og boligareal) i populasjonen
- Vi ønsker å estimere linjen som best beskriver denne lineære sammenhengen
 - basert på vårt utvalg
- Setter opp følgende teoretisk regresjonsmodell:
- $Y = \beta_0 + \beta_1 X + \epsilon_i$
 - ϵ_i omtales som regresjonens feilledd (error term)
 - Y_i og X_i er kjent fra dataene våre.
 - Fra utvalgsdataene estimerer vi de sanne populasjonskoeffisientene β_0 og β_1 .

(Tiltenkt eksempel) salgspris og boligens areal




(Tiltenkt eksempel) salgspris og boligens areal

Bolig nr	Areal	Salgspris
1	80	4 325
2	73	3 850
3	62	3 250
4	66	2 200
5	37	2 525
6	180	5 000
7	173	5 150
8	129	3 990
9	117	6 150
10	191	8 750
sum	110,8	4 519




(Tiltenkt eksempel) salgspris og boligens areal


Bolig nr	Areal	Salgspris
1	80	4 325
2	73	3 850
3	62	3 250
4	66	2 200
5	37	2 525
6	180	5 000
7	173	5 150
8	129	3 990
9	117	6 150
10	191	8 750
sum	110,8	4 519



(Tiltenkt eksempel) salgspris og boligens areal



(Tiltenkt eksempel) salgspris og boligens areal




Utrekning av koeffisienter

1	2	3	4	5	6	7	8	9
Bolig nr	Areal	Gj.snitt	Avvik	Avvik kvadrert	Salgspris	Gj.snitt	Avvik	Produkt avvik
1	80	110,8	-30,8	949	4 325 000	4 519 000	-194 000	5 975 200
2	73	110,8	-37,8	1 429	3 850 000	4 519 000	- 669 000	25 288 200
3	62	110,8	-48,8	2 381	3 250 000	4 519 000	-1 269 000	61 927 200
4	66	110,8	-44,8	2 007	2 200 000	4 519 000	-2 319 000	103 891 200
5	37	110,8	-73,8	5 446	2 525 000	4 519 000	-1 994 000	147 157 200
6	180	110,8	69,2	4 789	5 000 000	4 519 000	481 000	33 285 200
7	173	110,8	62,2	3 869	5 150 000	4 519 000	631 000	39 248 200
8	129	110,8	18,2	331	3 990 000	4 519 000	-529 000	- 9 627 800
9	117	110,8	6,2	38	6 150 000	4 519 000	1 631 000	10 112 200
10	191	110,8	80,2	6 432	8 750 000	4 519 000	4 231 000	339 326 200
sum				27 672			-	756 583 000

$$\hat{b} \text{ (helningskoeffisienten)} = 756\,583\,000 / 27\,672 = 27\,341$$

$$\hat{b}_0 \text{ (konstanten)} = 4\,519\,000 - 27\,341 \times 110,8 = 1\,489\,562$$


Hvor god tilpasning gir modellen?



Hvor god tilpasning gir modellen?

SSR

Merk at SSR beregnes for avstand fra linjen, til gjennomsnittsverdi (Dette er det som er forklart av estimert linje)




Gjennomsnitt av Y / snittverdi av alle Y

Hvor god tilpasning gir modellen?

SSE {

Merk at SSE beregnes for alle punktene, fra punkt til estimert linje; (som er da størrelse på det som ikke er estimert)



Gjennomsnitt av Y
/snittverdi av alle Y

Forklart varians: R^2

SST (Sum of Squares Total) = SSR (Sum of Squares Regression) + SSE (Sum of Squares Errors)

$R^2 = SSR / SST$ (varierer fra 0 til 1)

Hva sier R^2 ?

1. Hvor mye bedre er regresjonslinja enn gjennomsnittslinja
– hvor mye reduserer vi feilprediksjonen?
2. **Hvor mye av variansen kan vi forklare ved hjelp av regresjonsmodellen?**

NB! Mål på samvariasjon. Beviser ingen forklaring i kausal forstand

- Bivariat tilfelle: R^2 vil være lik den kvadrerte Pearson r

Utrekning av R^2

Bolig nr	Salgspris	Areal	Gjennomsnitt	Predikert	SST (salgspris-gj.snitt) ²	SSR (predikert-gj.snitt) ²	SSE (salgspris-predikert) ²
1	4 325	80	4 519	3 677	37 636	709 163	420 057
2	3 850	73	4 519	3 485	447 561	1 068 140	132 867
3	3 250	62	4 519	3 185	1 610 361	1 780 263	4 260
4	2 200	66	4 519	3 294	5 377 761	1 500 378	1 197 057
5	2 525	37	4 519	2 501	3 976 036	4 071 527	567
6	5 000	180	4 519	6 411	231 361	3 579 784	1 991 010
7	5 150	173	4 519	6 220	398 161	2 892 180	1 144 132
8	3 990	129	4 519	5 017	279 841	247 621	1 053 939
9	6 150	117	4 519	4 689	2 660 161	28 736	2 135 932
10	8 750	191	4 519	6 712	17 901 361	4 808 320	4 154 308
sum		110,8			32 920 240	20 686 113	12 234 127

$$R^2 = \text{SSR/SST} = \frac{20\,686\,113}{32\,920\,240} = ,628$$

Enkel regresjon estimering

Følgende vil alltid gjelde:

1. $\hat{Y}_i = \hat{b}_0 + \hat{b}_1 X_i$ --> for alle enheter i utvalget kan vi beregne den estimerte verdien for den **avhengige** variabelen
2. $\hat{e}_i = Y_i - \hat{Y}_i$ --> for alle enheter i utvalget kan vi estimere residualen (restleddet)
3. $Y_i = \hat{b}_0 + \hat{b}_1 X_i + \hat{e}_i = \hat{Y}_i + \hat{e}_i$ --> summen av den estimerte verdien for den avhengige variabelen ($\hat{Y}$) og residualet ($\hat{e}$) gir vi oss den observerte verdien for Y_i fra utvalget.
4. Det kan bevises matematisk at MKM (minste kvadraters metode) gir oss de beste lineære, forventingsrette estimatorene
 1. (**eng.;** **OLS – Ordinary Least Squares**)

Salgspris og boligens størrelse (n=10)

Model Summary

Model	R	R Square	Adjusted R Square	Std. Error of the Estimate
1	,793 ^a	,628	,582	1236,635

a. Predictors: (Constant), areal Boligens areal

Summen av kvadrerte avvik mellom predikert verdi og gjennomsnitt

ANOVA^a

Model		Sum of Squares	df	Mean Square	F	Sig.
1	Regression	20686112,69	1	20686112,69	13,527	,006 ^b
	Residual	12234127,31	8	1529265,914		
	Total	32920240,00	9			

a. Dependent Variable: salgspris Boligens salgspris (mill kr)


b. Predictors: (Constant), areal Boligens areal

Summen av kvadrerte avvik mellom faktisk og predikert verdi

Coefficients^a

Model		Unstandardized Coefficients	Standardized Coefficients	t	Sig.
1	(Constant)	1489,562		1,634	,141
	areal Boligens areal	27,341	,793	3,678	,006

a. Dependent Variable: salgspris Boligens salgspris (mill kr)



(1) Model Summary

Hvor godt beskriver areal, salgspris på en bolig?

Forklaringsgraden (R^2) $\rightarrow R^2 = 0,628 = 62,8\%$

Areal forklarer 62,8% % av variasjonen i boligpris

Model Summary				
Model	R	R Square	Adjusted R Square	Std. Error of the Estimate
1	,793 ^a	,628	,582	1236,635

a. Predictors: (Constant), areal Boligens areal

Forklaringsgraden (R^2) skal være $1 \geq R^2 \geq 0$


- Jo høyere R^2 , desto mer forklarer den uavhengige variabelen
- Jo høyere R^2 , desto bedre regresjonsmodell
- Hvis vi inkluderer mer enn 1 uavhengig variabel i modellen, benytter vi da **Adjusted R^2**
- HUSK: dette er svært få observasjoner, med tilhørende problemer, så R^2 verdien er kunstig høy her, og må se i sammenheng med feilmarginen!

T-test i regresjonsanalyse

- Hypoteser:
 - $H_0: \beta_i = 0$;
 - $H_1: \beta_i \neq 0$ (to-veis test)
- Testobservator: $t = \hat{b}_1 / SE(\hat{b}_1)$, S
 - E=standard error (standardfeilen) til regresjonskoeffisienten
- T-verdien viser hvor mange standardfeil regresjonskoeffisienten i utvalget befinner seg fra 0 (som H_0 antar)
- Frihetsgrader (df) i regresjonsanalyse: $df = n - k - 1$
- **→ n = antall observasjoner; k =antall uavhengige variabler**
- $df \leq 100 \Rightarrow$ bruker t -fordelingen for å finne kritisk verdi (forkastningsverdi)
- $df > 100 \Rightarrow$ bruker 1,96 som kritisk verdi på 5%-nivå


T-test i regresjonsanalyse

- Hypoteser:
 - $H_0: \beta_i = 0$;
 - $H_1: \beta_i \neq 0$ (to-veis test)
- Hva betyr det at « $H_0: \beta_i = 0$ »
 - Hvordan ser linjen ut dersom $\beta_i = 0$?




T-test i regresjonsanalyse

- Hypoteser:
 - $H_0: \beta_i = 0$;
 - $H_1: \beta_i \neq 0$ (to-veis test)
- Hva betyr det at « $H_0: \beta_i = 0$ »
 - Hvordan ser linjen ut dersom $\beta_i = 0$?
 - For hver kvadratmeter boligarealet går opp, går prisen opp med 0




T-test i regresjonsanalyse

- Hypoteser:
 - $H_0: \beta_i = 0$;
 - $H_1: \beta_i \neq 0$ (to-veis test)
- Hva betyr det at « $H_0: \beta_i = 0$ »
 - Hvordan ser linjen ut dersom $\beta_i = 0$?
 - For hver kvadratmeter boligarealet går opp, går prisen opp med 0
- Hva betyr: $H_1: \beta_i \neq 0$ (to-veis test)
 - At linjen IKKE er flat i populasjonen
 - Kan være at den går oppover
 - Kan være at den går nedover
- Dersom vi forkaster H_0 : sier vi at den er:
statistisk signifikant [forskjellig fra null]




Nullhypotese: Det er ikke samvariasjonen mellom variablene i populasjonen

(i eksempelet, bruker jeg Pearson korrelasjon, samme logikk for regresjon, men ikke begrenset i til mellom -1 og 1))




Nullhypotese: Det er ikke samvariasjonen mellom variablene i populasjonen

(i eksempelet, bruker jeg Pearson korrelasjon, samme logikk for regresjon, men ikke begrenset i til mellom -1 og 1))




Nullhypotese: Det er ikke samvariasjonen mellom variablene i populasjonen

(i eksempelet, bruker jeg Pearson korrelasjon, samme logikk for regresjon, men ikke begrenset i til mellom -1 og 1))



Nullhypotese: Det er ikke samvariasjonen mellom variablene i populasjonen

(i eksempelet, bruker jeg Pearson korrelasjon, samme logikk for regresjon, men ikke begrenset i til mellom -1 og 1))



Signifikanstesting, er for å se om det er grunn til å tro at estimatet er forskjellig fra null i populasjonen

		høyresiden	
Plassering på venstre- eller høyresiden	Pearson Correlation	1	-,156**
	Sig. (2-tailed)		<,001
	N	1497	1477
I hvilken grad føler du et personlig ansvar for å prøve å redusere klimaendringene?	Pearson Correlation	-,156**	1
	Sig. (2-tailed)	<,001	
	N	1477	1522

** Correlation is significant at the 0.01 level (2-tailed)

T-test i regresjonsanalyse

- Hypoteser:
 - $H_0: \beta_i = 0$;
 - $H_1: \beta_i \neq 0$ (to-veis test)
- Oppgave:
 - Skriv ut en Hypotese som passer for boligpris eksempelet, der vi estimerer pris, på areal?

T-test i regresjonsanalyse

- Hypoteser:
 - $H_0: \beta_i = 0$;
 - $H_1: \beta_i \neq 0$ (to-veis test)
- Oppgave:
 - Skriv ut en Hypotese som passer for boligpris eksempelet, der vi estimerer pris, på areal?
 - $H_0: \beta_i = 0$; Det er ingen sammenheng mellom bolig størrelse og salgspris
 - $H_1: \beta_i \neq 0$ (to-veis test); Det er en sammenheng mellom boligens størrelse og salgspris
 -

T-test i regresjonsanalyse

- Hypoteser:
 - $H_0: \beta_i = 0$;
 - $H_1: \beta_i \neq 0$ (to-veis test)
- Testobservator: $t = \hat{b}_1 / SE(\hat{b}_1)$, S
 - E=standard error (standardfeilen) til regresjonskoeffisienten
- T-verdien viser hvor mange standardfeil regresjonskoeffisienten i utvalget befinner seg fra 0 (som H_0 antar)
- Frihetsgrader (df) i regresjonsanalyse: $df = n - k - 1$
- **→ n = antall observasjoner; k =antall uavhengige variabler**
- $df \leq 100 \Rightarrow$ bruker t -fordelingen for å finne kritisk verdi (forkastningsverdi)
- $df > 100 \Rightarrow$ bruker 1,96 som kritisk verdi på 5%-nivå

Coefficients^a

Model		Unstandardized Coefficients		Standardized Coefficients	t	Sig.
		B	Std. Error	Beta		
1	(Constant)	1489,562	911,807		1,634	,141
	areal Boligens areal	27,341	7,434	,793	3,678	,006

a. Dependent Variable: salgspris Boligens salgspris (mill kr)

- Hypoteser: $H_0: \beta_i = 0$; $H_1: \beta_i \neq 0$ (to-veis test)
- Testobservator: $t = \hat{b}_1 / SE(\hat{b}_1)$: $27,341 / 7,434 = 3,678$
- $df = 10 - 1 - 1 = 8$
- Kritisk verdi 95%-nivå: $t_8 = 2,306$
- Vår observerte t-verdi er over kritisk verdi (og tilhørende p-verdi (Sig.) under 0,05).
- Konklusjon: H_0 forkastes (vi kan anta at $\beta_i \neq 0$).
- **Oppgave:** Beregn konfidensintervallet

Coefficients^a

Model		Unstandardized Coefficients		Standardized Coefficients	t	Sig.
		B	Std. Error	Beta		
1	(Constant)	1489,562	911,807		1,634	,141
	areal Boligens areal	27,341	7,434	,793	3,678	,006

a. Dependent Variable: salgspris Boligens salgspris (mill kr)

- Hypoteser: $H_0: \beta_i = 0$; $H_1: \beta_i \neq 0$ (to-veis test)
- Testobservator: $t = \hat{b}_1 / SE(\hat{b}_1)$: $27,341 / 7,434 = 3,678$
- $df = 10 - 1 - 1 = 8$
- Kritisk verdi 95%-nivå: $t_8 = 2,306$
- Vår observerte t-verdi er over kritisk verdi (og tilhørende p-verdi (Sig.) under 0,05).
- Konklusjon: H_0 forkastes (vi kan anta at $\beta_i \neq 0$).
- **Oppgave:** Beregn konfidensintervallet
 - For 95% konfidensintervall, og liten n, er kritisk nivå: $t_8 = 2,306$
 - Multipliser nivået med standard feil (st. error) : $2,306 * 7.434$
 - Beregn intervallet, ved å trekke fra, og legge til beta verdien, for å finne intervallet.

Coefficients^a

Model		Unstandardized Coefficients		Standardized Coefficients	t	Sig.
		B	Std. Error	Beta		
1	(Constant)	1489,562	911,807		1,634	,141
	areal Boligens areal	27,341	7,434	,793	3,678	,006

a. Dependent Variable: salgspris Boligens salgspris (mill kr)

- Hypoteser: $H_0: \beta_i = 0$; $H_1: \beta_i \neq 0$ (to-veis test)
- Testobservator: $t = \hat{b}_1 / SE(\hat{b}_1)$: $27,341 / 7,434 = 3,678$
- $df = 10 - 1 - 1 = 8$
- Kritisk verdi 95%-nivå: $t_8 = 2,306$
- Vår observerte t-verdi er over kritisk verdi (og tilhørende p-verdi (Sig.) under 0,05).
- Konklusjon: H_0 forkastes (vi kan anta at $\beta_i \neq 0$).
- **Oppgave:** Beregn konfidensintervallet
 - For 95% konfidensintervall, og liten n, er kritisk nivå: $t_8 = 2,306$
 - Multipliser nivået med standard feil (st. error) : $2,306 * 7.434$
 - Beregn intervallet, ved å trekke fra, og legge til beta verdien, for å finne intervallet.
 - Konfidensintervall = $27.341 \pm (2,306 * 7.434) = 27.341 \pm (17.142) = 10.198 \text{ til } 44.484$

Resultater fra Python

Y
(avhengig variable)

OLS Regression Results

Dep. Variable:	pris	R-squared:	0.713
Model:	OLS	Adj. R-squared:	0.713
Method:	Least Squares	F-statistic:	2513.
Date:	Sun, 09 Feb 2025	Prob (F-statistic):	0.00
Time:	16:20:22	Log-Likelihood:	-31603.
No. Observations:	2026	AIC:	6.321e+04
Df Residuals:	2023	BIC:	6.323e+04
Df Model:	2		
Covariance Type:	nonrobust		

	coef	std err	t	P> t	[0.025	0.975]
const	8.061e+05	7.18e+04	11.234	0.000	6.65e+05	9.47e+05
BOAProm	3.831e+04	540.414	70.897	0.000	3.73e+04	3.94e+04
alder	798.8393	582.213	1.372	0.170	-342.961	1940.640

Omnibus:	309.852	Durbin-Watson:	1.139
Prob(Omnibus):	0.000	Jarque-Bera (JB):	1423.409
Skew:	0.655	Prob(JB):	8.14e-310
Kurtosis:	6.891	Cond. No.	292.

Notes:

[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

R^2

Konfidensintervall

β_i estimerte koeffisienter

t og p verdier
(signifikanstesting)

Resultater rapportert i APA-7 stil

Table X

Multiple Regression Analysis Predicting Price (Pris)

Predictor	B	SE	t	p	95% CI (LL, UL)
Constant	806,100	71,800	11.23	< .001	[665,000, 947,000]
BOAProm	38,310	540.41	70.90	< .001	[37,300, 39,400]
Alder	798.84	582.21	1.37	.170	[-342.96, 1,940.64]

Note.

B = unstandardized coefficient, SE = standard error, CI = confidence interval, LL = lower limit, UL = upper limit.

p values are two-tailed. $R^2 = .713$, Adjusted $R^2 = .713$, $F(2, 2023) = 2513.00$, $p < .001$.


Resultater rapportert i APA-7 stil

Table X
Multiple Regression Analysis Predicting Price (Pris)

Predictor	B	SE	t	p	95% CI (LL, UL)
Constant	806,100	71,800	11.23	< .001	[665,000, 947,000]
BOAProm	38,310	540.41	70.90	< .001	[37,300, 39,400]
Alder	798.84	582.21	1.37	.170	[-342.96, 1,940.64]

Note.

B = unstandardized coefficient, SE = standard error, CI = confidence interval, LL = lower limit, UL = upper limit.
 p values are two-tailed. $R^2 = .713$, Adjusted $R^2 = .713$, $F(2, 2023) = 2513.00$, $p < .001$.



Salgspris og boligens størrelse (n=2026)

Model Summary

Model	R	R Square	Adjusted R Square	Std. Error of the Estimate
1	,844 ^a	,713	,713	1441,15828

a. Predictors: (Constant), BOA/P-rom

ANOVA^a

Model		Sum of Squares	df	Mean Square	F	Sig.
1	Regression	1,043E+10	1	1,043E+10	5022,351	,000 ^b
	Residual	4203720857	2024	2076937,182		
	Total	1,463E+10	2025			

a. Dependent Variable: Salgspris i mill kr

b. Predictors: (Constant), BOA/P-rom

Coefficients^a

Model		Unstandardized Coefficients		Standardized Coefficients	t	Sig.
		B	Std. Error	Beta		
1	(Constant)	843,319	66,435		12,694	,000
	BOA/P-rom	38,299	,540	,844	70,869	,000

a. Dependent Variable: Salgspris i mill kr

Multippel regresjonsanalyse

Multippel regresjonsanalyse

Tar inn flere uavhengige variabler i regresjonsligningen, fordi:

- Ønsker å få et mer fullstendig bilde av årsaks-variabler (øke R^2)
 - Bedre forståelse for fenomenet
 - Bedre prediksjonskraft
- Ønsker å kontrollere for bakenforliggende tredjevariabler
 - Unngå spuriøse sammenhenger
 - Bedre forståelse for fenomenet
- Nøkkelspørsmål
 - I gjennomsnitt, hvor mye endres Y når X_n endres med en enhet, kontrollert for effekten av de andre X -variablene?
 - Hvor mye forbedrer vi R^2 ved å ta inn flere forklaringsvariabler?

Multippel regresjonsanalyse

- Modellen som skal estimeres (basert på utvalget)
- Enkel regresjon: $\hat{Y}_i = b_0 + b_1 X_{1i}$
 - *Eksempel: Boligpris = basispris + b_1 (kvadratmeter)*
- Multippel regresjon: $\hat{Y}_i = b_0 + b_1 X_{1i} + b_2 X_{2i} + \dots + b_k X_{ki}$
 - «i» er en indeks og tar verdier fra 1,2,...,n hvor n er antall observasjoner i utvalget
 - k = antall uavhengige variabler

Eksempel boligpriser

Eiendomsdata - modellen som skal estimeres:

- $Y = b_0 + b_1X_1 + b_2X_2 + b_3X_3 + b_4X_4$
 - Y = salgspris
 - X_1 = boligareal
 - X_2 = beliggenhet
 - X_3 = boligens energimerking
 - X_4 = type bolig
- Modellen kan også skrives som:
 - Salgspris = basispris + b_1 *boligareal + b_2 *beliggenhet + b_3 * boligens energimerking + b_4 * type bolig

Eksempel boligpriser

Eiendomsdata - modellen som skal estimeres:

- $Y = b_0 + b_1 X_1 + b_2 X_2 + b_3 X_3 + b_4 X_4$
 - Y = salgspris
 - X_1 = boligareal
 - X_2 = beliggenhet
 - X_3 = boligens energimerking
 - X_4 = type bolig
- Modellen kan også skrives som:
 - $\text{Salgspris} = \text{basispris} + b_1 * \text{boligareal} + b_2 * \text{beliggenhet} + b_3 * \text{boligens energimerking} + b_4 * \text{type bolig}$

Eksempel boligpriser

Eiendomsdata - modellen som skal estimeres:

- $Y = b_0 + b_1X_1 + b_2X_2 + b_3X_3 + b_4X_4$
 - Y = salgspris (forholdstallsnivå)
 - X_1 = boligareal (forholdstallsnivå)
 - X_2 = beliggenhet (nominal – dummy)
 - Oslo vest eller ikke.
 - X_3 = boligens energimerking (ordinalnivå)
 - Verdier fra A-G
 - X_4 = type bolig (nominalnivå)
 - Enebolig, leilighet, Rekkehus eller tomannsbolig

Eksempel boligpriser

Descriptive Statistics

	N	Minimum	Maximum	Mean		Std. Deviation	Skewness		Kurtosis	
	Statistic	Statistic	Statistic	Statistic	Std. Error	Statistic	Statistic	Std. Error	Statistic	Std. Error
Salgspris	2027	1100000	27000000	4969774,00	59707,353	2688157,410	1,493	,054	4,152	,109
BOA/P-rom	2031	18	449	107,70	1,316	59,291	1,107	,054	1,422	,109
Valid N (listwise)	2026									

Ordinal verdi

Energimerking

		Frequency	Percent	Valid Percent	Cumulative Percent
Valid	A	2	,1	,1	,1
	B	40	2,0	2,0	2,1
	C	209	10,3	10,3	12,4
	D	367	18,1	18,1	30,4
	E	306	15,1	15,1	45,5
	F	474	23,3	23,3	68,8
	G	633	31,2	31,2	100,0
	Total	2031	100,0	100,0	
Missing	System	1	,0		
	Total	2032	100,0		

Descriptive Statistics

	N	Minimum	Maximum	Mean		Std. Deviation	Skewness		Kurtosis	
	Statistic	Statistic	Statistic	Statistic	Std. Error	Statistic	Statistic	Std. Error	Statistic	Std. Error
Energimerking	2031	1	7	5,41	,032	1,449	-,495	,054	-,906	,109
Valid N (listwise)	2031									

Type bolig

		Frequency	Percent	Valid Percent	Cumulative Percent
Valid	Enebolig	388	19,1	19,1	19,1
	Leilighet	1157	56,9	56,9	76,0
	Rekkehus	279	13,7	13,7	89,8
	Tomannsbolig	208	10,2	10,2	100,0
	Total	2032	100,0	100,0	

Boligen ligger på Oslo vest

		Frequency	Percent	Valid Percent	Cumulative Percent
Valid	0	1384	68,1	68,1	68,1
	1	648	31,9	31,9	100,0
	Total	2032	100,0	100,0	

Nominalnivå
- Ingen naturlig forhold; kun kategorier

Nominal,
binært!

Dummy-variabler

- Dummy-variabel: Kategorisk variabel som innehar kun to verdier (0 og 1)
- Brukes for å markere tilhørighet til en kategori/gruppe
 - (f.eks. ledere og ikke-ledere, kvinner og menn, bransje etc.)
- En gruppe gis verdien «0» (ikke-ledere) og den andre «1» (ledere)
- Gruppen som er kodet «0» kalles referansegruppen

Dummy-variabler

- Når det er flere enn to kategorier, trenger vi $G-1$ antall variabler
 - (G =antall grupper/kategorier)
 - F.eks. en bedrift ønsker å se om kundetilfredsheten er påvirket av hvor kunden er lokalisert. Landet er delt i fem salgsdistrikt; Østlandet, Sørlandet, Vestlandet, Midt-Norge og Nord-Norge. Her må det lages fire dummy-variabler:
 - Sørlandet (0/1), Vestlandet (0/1), Midt-Norge (0/1), Nord-Norge (0/1)
 - Østlandet blir referansekategori (som de andre salgsdistriktene sammenlignes mot)
 - Vi får verdi for Østlandet, når alle andre er null.
- Referansekategorien:
 - Bør være gruppen man forventer har den høyeste skåren på Y
 - Bør være godt definert og forstått (ikke en «samlekategori»)
 - Bør ikke være for liten med tanke på antall observasjoner
- Hver av helningskoeffisientene (« b » i modellen) viser hvor mye høyere/lavere gjennomsnittet på avhengig variabel er for den gruppen koeffisienten gjelder (1) sammenlignet med referansegruppen

Dummy-variabler – diktom nominal variabel

- Det er kun dikotome kategoriske variable man kan bruke i lineær regresjonsanalyse som uavhengige variabler, ved siden av ordinal og metriske variabler.
 - En diktom (binær) kategorisk variable er naturlig en dummy variabel
 - «Beliggenhet» er en diktom nominal variabel som gir boliger som er lokalisert på Oslo vest verdien 1, mens boliger som er lokalisert andre steder i byen får verdien 0

Type bolig

Type bolig				
		Frequency	Percent	Cumulative Percent
Valid	Enebolig	388	19.1	19.1
	Leilighet	1157	56.9	76.0
	Rekkehus	279	13.7	89.8
	Tomannsbolig	208	10.2	100.0
	Total	2032	100.0	100.0

MERK: i en regresjon, skal KUN tre av disse fire inkluderes. Den siste, blir referanseverdien (det som er igjen, når alle de andre er «0»).

The screenshot shows the IBM SPSS Statistics Viewer interface with four frequency tables displayed on the right side. The left pane shows a tree view of the output, with orange arrows pointing from specific tables to the summary table on the left.

Enebolig

	Frequency	Percent	Valid Percent	Cumulative Percent
Valid 0	1644	80.9	80.9	80.9
1	388	19.1	19.1	100.0
Total	2032	100.0	100.0	

Leilighet

	Frequency	Percent	Valid Percent	Cumulative Percent
Valid 0	875	43.1	43.1	43.1
1	1157	56.9	56.9	100.0
Total	2032	100.0	100.0	


Rekkehus

	Frequency	Percent	Valid Percent	Cumulative Percent
Valid 0	1753	86.3	86.3	86.3
1	279	13.7	13.7	100.0
Total	2032	100.0	100.0	

Tomannsbolig

	Frequency	Percent	Valid Percent	Cumulative Percent
Valid 0	1824	89.8	89.8	89.8
1	208	10.2	10.2	100.0
Total	2032	100.0	100.0	

Dummy-variabler – diktom, Oslo vest



Oslo vest					
		Frequency	Percent	Valid Percent	Cumulative Percent
Valid	0	1384	68,1	68,1	68,1
	1	648	31,9	31,9	100,0
	Total	2032	100,0	100,0	

Report			
Pris Salgspris			
West Oslo vest	Mean	N	Std. Deviation
0	4321230,19	1381	2384343,596
1	6356212,07	646	2776485,448
Total	4969774,00	2027	2688157,410



Merk:

- ca. 2 000 000kr snitt dyrere i Oslo Vest
- Ca. 400 000kr større standardavvik (spredning) i Oslo vest

Dummy variabel for kategorivariabel med flere verdier



- «Boligtype» er en kategorivariabel med fire kategorier
 - Lag en dummyvariabel (0/1) for **hver gruppe** som beskriver om observasjonen tilhører kategorien eller ikke.
- Det skal være $k-1$ dummyvariablene i regresjonen
 - For boligtype: tre dummier.
 - En av kategoriene skal fungere som basis, de andre skal sammenliknes med/ er relativt til.

Dummy-variabler (boligtype)



Report

Salgspris			
Type bolig	Mean	N	Std. Deviation
Enebolig	7653033,30	387	2943966,434
Leilighet	3521800,69	1154	1560097,936
Rekkehus	5853291,37	278	1951664,626
Tomannsbolig	6829975,96	208	2497164,503
Total	4969774,00	2027	2688157,410



Eksempel boligpriser

Model Summary

Model	R	R Square	Adjusted R Square	Std. Error of the Estimate
1	,844 ^a	,713	,713	1441458,602
2	,867 ^b	,752	,751	1340875,483

a. Predictors: (Constant), BOA/P-rom

b. Predictors: (Constant), BOA/P-rom, Energimerking, Rekkehus, Beliggenhet Oslo vest, Tomannsbolig, Leilighet

Coefficients^a

Model		Unstandardized Coefficients		Standardized Coefficients	t	Sig.
		B	Std. Error	Beta		
1	(Constant)	842889,108	66457,817		12,683	<,001
	BOA/P-rom	38305,921	540,798	,844	70,832	,000
2	(Constant)	1189120,291	192995,011		6,161	<,001
	BOA/P-rom	36526,904	782,684	,805	46,669	,000
	Energimerking	-89749,107	20734,477	-,048	-4,328	<,001
	Leilighet	-31922,546	116187,228	-,006	-,275	,784
	Rekkehus	-182299,476	112367,316	-,023	-1,622	,105
	Tomannsbolig	236594,386	118806,136	,027	1,991	,047
	Beliggenhet Oslo vest	1097854,352	65786,981	,190	16,688	<,001

a. Dependent Variable: Salgspris

Eksempel boligpriser

Model Summary

Model	R	R Square	Adjusted R Square	Std. Error of the Estimate
1	,844 ^a	,713	,713	1441458,602
2	,867 ^b	,752	,751	1340875,483

a. Predictors: (Constant), BOA/P-rom

b. Predictors: (Constant), BOA/P-rom, Energimerking, Rekkehus, Beliggenhet Oslo vest, Tomannsbolig, Leilighet

Coefficients^a

Model		Unstandardized Coefficients		Standardized Coefficients	t	Sig.
		B	Std. Error	Beta		
1	(Constant)	842889,108	66457,817		12,683	<,001
	BOA/P-rom	38305,921	540,798	,844	70,832	,000
2	(Constant)	1189120,291	192995,011		6,161	<,001
	BOA/P-rom	36526,904	782,684	,805	46,669	,000
	Energimerking	-89749,107	20734,477	-,048	-4,328	<,001
	Leilighet	-31922,546	116187,228	-,006	-,275	,784
	Rekkehus	-182299,476	112367,316	-,023	-1,622	,105
	Tomannsbolig	236594,386	118806,136	,027	1,991	,047
	Beliggenhet Oslo vest	1097854,352	65786,981	,190	16,688	<,001

a. Dependent Variable: Salgspris

Adjusted R-square

- Korrigerer for antall forklaringsvariabler i modellen
 - Brukes når man skal sammenligne modeller
- Ujustert R² vil alltid øke når vi legger til variabler i modellen
- R²_{adj} alltid lavere enn R²
- n er antall observasjoner i utvalget og k er antall variabler i regresjonen.
- Korrigeringen (nedjusteringen) øker når det er mange uavhengige variabler i forhold til observasjoner, og er større ved lav R² enn ved høy R²
- I motsetning til R² som bare kan ta verdier mellom 0 og 1, kan R²_{adj} ha negative verdier

$$R_{[adj]}^2 = 1 - \left[\frac{(1 - R^2)(n - 1)}{n - k - 1} \right]$$

Adjusted R-square : Eksempel

R2	n	k	Adjusted R2	Differanse	R2	n	k	Adjusted R2	Differanse
0.5	50	3	0.467	-0.033	0.5	100	2	0.490	-0.010
0.5	100	3	0.484	-0.016	0.5	100	5	0.473	-0.027
0.5	500	3	0.497	-0.003	0.5	100	10	0.444	-0.056
0.5	1000	3	0.498	-0.002	0.5	100	15	0.411	-0.089
0.5	2000	3	0.499	-0.001	0.5	100	30	0.283	-0.217

Jo høyere observasjoner (n),
jo mindre blir differansen
mellom R2 og Adj. R2

Jo flere variabler (k), jo
større blir differansen
mellom R2 og Adj. R2

$$R_{[adj]}^2 = 1 - \left[\frac{(1 - R^2)(n - 1)}{n - k - 1} \right]$$

Eksempel boligpriser: Adjusted R-square

- Modell 1 (bivariat) forklarer 71 prosent av variasjonen i den avhengige variabelen, mens modell 2 (multivariat) forklarer 75 prosent.
- Merk at forskjellen mellom R^2_{adj} og R^2 her er liten. Hvorfor?
- Koeffisienten R er Pearson korrelasjonskoeffisient mellom predikerte verdier på y (dvs. $\hat{y}$) og observerte verdier. R^2 er lik R i annen potens.

Model Summary				
Model	R	R Square	Adjusted R Square	Std. Error of the Estimate
1	,844 ^a	,713	,713	1441458,602
2	,867 ^b	,752	,751	1340875,483

a. Predictors: (Constant), BOAP-rom

b. Predictors: (Constant), BOAP-rom, Energimerking, Rekkehus, Beliggenhet Oslo vest, Tomannsbolig, Leilighet

ANOVA-test i regresjonsanalyse

- $H_0: b_1 = b_2 = b_3 = b_4 = 0$
- H_1 : Minst en av beta-ene er forskjellig fra null

ANOVA^a

Model		Sum of Squares	df	Mean Square	F	Sig.
1	Regression	1,042E+16	1	1,042E+16	5017,207	,000 ^b
	Residual	4,203E+15	2023	2,078E+12		
	Total	1,463E+16	2024			
2	Regression	1,100E+16	6	1,833E+15	1019,673	,000 ^c
	Residual	3,628E+15	2018	1,798E+12		
	Total	1,463E+16	2024			

Sig. = p-verdien for testobservatoren F

a. Dependent Variable: Salgspris

b. Predictors: (Constant), BOA/P-rom

c. Predictors: (Constant), BOA/P-rom, Energimerking, Rekkehus, Beliggenhet Oslo vest, Tomannsbolig, Leilighet

ANOVA-test i regresjonsanalyse

Testobservator: $F = \frac{\frac{SSR}{k}}{\frac{SSE}{n-k-1}}$ $k = \text{antall uavhengige variabler}$
 $n = \text{antall observasjoner.}$

- P -verdien for F i modell 2 er $< 0,000$ ($\alpha < ,05$) og dermed forkaster vi H_0
- Konklusjon: Ikke alle beta-ene er lik null, og dermed kan vi konkludere med at regresjonsmodellen vår har signifikant bedre forklaringskraft enn om vi bare ser på gjennomsnittet av det avhengige variabelen.

Tolkning av koeffisienter

- Tolkning av koeffisientene - multippel regresjon
- H_0 : b_i -koeffisienten = 0, hvor i er 0,1,2,3,4
- H_1 : b_i -koeffisienten $\neq 0$
 - Her er det i praksis 6 hypoteser
- Testobservator: $t = (b_i/SE(b_i))$ (SE = Standard Error, dvs. standardfeilen til regresjonskoeffisienten)
- Testobservator er studentfordelt med $N-k$ antall frihetsgrader i små utvalg, og normalfordelt i store utvalg
- Hva er konklusjonen?

Coefficients^a

Model		Unstandardized Coefficients		Standardized Coefficients	t	Sig.
		B	Std. Error	Beta		
1	(Constant)	842889,108	66457,817		12,683	<,001
	BOA/P-rom	38305,921	540,798	,844	70,832	,000
2	(Constant)	1189120,291	192995,011		6,161	<,001
	BOA/P-rom	36526,904	782,684	,805	46,669	,000
	Energimerking	-89749,107	20734,477	-,048	-4,328	<,001
	Leilighet	-31922,546	116187,228	-,006	-,275	,784
	Rekkehus	-182299,476	112367,316	-,023	-1,622	,105
	Tomannsbolig	236594,386	118806,136	,027	1,991	,047
	Beliggenhet Oslo vest	1097854,352	65786,981	,190	16,688	<,001

a. Dependent Variable: Salgspris

Standardisert regresjonskoeffisient


- Ulik målestokk på uavhengige variabler gir problemer med å tolke den relative effekten (eks. boligareal vs. energieffektivitet)
- Den ustandardiserte regresjonskoeffisienten er ikke normert
- Standardisert regresjonskoeffisient er normert med utgangspunkt i standardavviket til den uavhengige og avhengige variabelen
- Tolkning: Endring i antall standardavvik for den avhengige variabelen når den uavhengige variabelen endres med ett standardavvik
- Kan brukes for å sammenligne de uavhengige variabelenes effekt på den avhengige variabelen
- *«Vi vil derfor anbefale at man først og fremst forholder seg til de ustandardiserte koeffisientene ved fortolkning av resultater fra regresjonsanalyser, og i hvert fall at man utviser forsiktighet ved bruk av standardiserte koeffisienter som mål på en uavhengig variabels forklaringskraft»*

Mer avanserte regresjonsmodeller

Mediasjon

Moderasjon

Medierende variabel



- Medierende variabel: en variabel som forklarer effekten mellom to andre variabler
 - Enten fullstendig, eller delvis.
- Enkel stianalyse, kan estimeres med OLS
- Grunnlag for å forstå årsakssammenhenger
- Får estimert den direkte, indirekte effekten (via arbeidstid) og totale effekten på lønn ved å være leder.'

Viktighet av Sosial kapital blant utlendinger




Målt ved:

- Antall venner
- Kvalitet på vennskap
 - Frekvens
 - Opplevd nærhet

Målt ved:

- Angst & depresjon
- Affektiv glede
- Andre velværemål

Viktighet av Sosial kapital blant utlendinger




Målt ved:

- Antall venner
- Kvalitet på vennskap
 - Frekvens
 - Opplevd nærhet

Målt ved:

- Angst & depresjon
- Affektiv glede
- Andre velværemål

Viktighet av Sosial kapital blant utlendinger





Målt ved:

- Antall venner
- Kvalitet på vennskap
 - Frekvens
 - Opplevd nærhet

Målt ved:

- Angst & depresjon
- Affektiv glede
- Andre velværemål

Medierende variabel



- Medierende variabel: en variabel som forklarer effekten mellom to andre variabler
 - Enten fullstendig, eller delvis.
- Enkel stianalyse, kan estimeres med OLS
- Grunnlag for å forstå årsakssammenhenger
- Får estimert den direkte, indirekte effekten (via ensomhet) og totale effekten på psykisk velvære av sosial kapital.
- Komplisert stianalyse (SEM-estimering)

Moderasjon: interaksjonseffekt



- Generelt antar vi at regresjonslinja har samme «bratthet» for alle observasjonene i datasettet vårt. Men effekten av en variabel kan være ulik for ulike grupper av enheter:
 - Effekten av samlivsbrudd på stressnivå er ulikt for kvinner og menn
- Foreligger det samspills-/interaksjonseffekter,
 - dvs. gir multiplikative b-er bedre tilpasningen til dataene enn additive?

Interaksjonseffekter

Coefficients^a

Beliggenhet Oslo vest	Model		Unstandardized Coefficients		Standardized Coefficients	t	Sig.
			B	Std. Error	Beta		
0	1	(Constant)	910639,253	77672,222		11,724	<,001
		BOA/P-rom	34209,206	679,009	,805	50,381	,000
1	1	(Constant)	1274652,880	101781,419		12,523	<,001
		BOA/P-rom	40682,649	729,783	,910	55,746	<,001

a. Dependent Variable: Salgspris



Interaksjonseffekter

- Det mest praktiske er å teste modererende effekter gjennom å lage interaksjonsvariabler
 - (her: areal*beliggenhet (BOAP-rom*vest))
- Koeffisienten for BOAP-rom viser priseffekten av en ekstra kvm for gruppen som har 0 i verdi på moderatorvariabelen (boliger i resten av Oslo)
- **Koeffisienten for interaksjonsleddet** viser hvor mye større effekten er for boliger på Oslo vest (verdi 1 på moderatorvariabelen)

Coefficients ^a						
Model		Unstandardized Coefficients		Standardized Coefficients	t	Sig.
		B	Std. Error	Beta		
1	(Constant)	910639,253	73376,784		12,410	<,001
	BOAP-rom	34209,206	641,458	,754	53,330	,000
	Beliggenhet Oslo vest	364013,627	139118,608	,063	2,617	,009
	areal_beliggenhet	6473,443	1062,856	,164	6,091	<,001

a. Dependent Variable: Salgspris

- Konklusjon: Beliggenhet modererer effekten av boligstørrelse på salgspris. Effekten av boligstørrelse på salgspris er 6 473 kroner høyere per kvm på Oslo vest enn i resten av byen

Graf effekten for bedre forståelse

Intecept	Coefficient	P-rom	Coefficient	OsloV	Interaskjon	Estimert pris
910639	34209	30	364013	0	6473	1936909
910639	34209	150	364013	0	6473	6041989
910639	34209	30	364013	1	6473	2495112
910639	34209	150	364013	1	6473	7376952
						"=A2+(B2*C2)+(D2*E2)+(F2*E2*C2)"



Velg to (eller fler)
verdier, høye og lave,
for å estimer pris




Formel for å regne ut pris på hvert nivå:
Estimert pris= konstant + (beta*p-rom) + (beta*OsloV)+(Interaksjon*OsloV*Prom)

Graf effekten for bedre forståelse

Intecept	Coefficient	P-rom	Coefficient	OsloV	Interaskjon	Estimert pris
910639	34209	30	364013	0	6473	1936909
910639	34209	150	364013	0	6473	6041989
910639	34209	30	364013	1	6473	2495112
910639	34209	150	364013	1	6473	7376952
						"=A2+(B2*C2)+(D2*E2)+(F2*E2*C2)"

	30	100
OsloV	2495112	7376952
OsloØ	1936909	6041989

Merk at avstanden mellom OsloVest og OsloØst er større for store boliger, enn små.




Graf effekten for bedre forståelse

Intecept	Coefficient	P-rom	Coefficient	OsloV	Interaskjon	Estimert pris
910639	34209	30	364013	0	6473	1936909
910639	34209	150	364013	0	6473	6041989
910639	34209	30	364013	1	6473	2495112
910639	34209	150	364013	1	6473	7376952
						"=A2+(B2*C2)+(D2*E2)+(F2*E2*C2)"

	30	100
OsloV	2495112	7376952
OsloØ	1936909	6041989

Merk at avstanden mellom OsloVest og OsloØst er større for store boliger, enn små.




Regresjonsanalyse – forutsetninger

Forutsetninger: variabler

- Avhengig variabel metrisk målenivå
 - (men også ordinalvariabler med mange kategorier benyttes)
- Uavhengig variabel: Alle typer variabler
- Variablene skal være uten målefeil
- Ikke null-varians
 - alle forklaringsvariablene må ha en viss varians

Forutsetninger: Modellspesifikasjon

- Alle relevante og ingen irrelevante variabler inkludert
- Lineær sammenheng mellom avhengig og uavhengig variabel
- Additivitet
 - Separate regresjonsmodeller
 - Interaksjonsledd
- Hvordan håndterer vi brudd?
 - Omkoding til dummy-variabler
 - Annengradsledd
 - Omkoding til logaritmer



F.eks: inntekt og alder fra «Sosial ulikhet»

- Regresjonsanalyse: Alder som funksjon for inntekt.
 - Jeg forventer at høyere alder er assosiert med høyere inntekt.
 - Se Johannessen, Christoffersen & Tufte for detaljer.

Variables Entered/Removed^a

Model	Variables Entered	Variables Removed	Method
1	Age of respondent, calculated ^b	.	Enter

a. Dependent Variable: Household's total net income, all sources

b. All requested variables entered.

Model Summary

Model	R	R Square	Adjusted R Square	Std. Error of the Estimate
1	.111 ^a	.012	.011	2.702

a. Predictors: (Constant), Age of respondent, calculated

ANOVA^a

Model		Sum of Squares	df	Mean Square	F	Sig.
1	Regression	121.534	1	121.534	16.651	.000 ^b
	Residual	9817.042	1345	7.299		
	Total	9938.576	1346			

a. Dependent Variable: Household's total net income, all sources

b. Predictors: (Constant), Age of respondent, calculated

Coefficients^a

Model		Unstandardized Coefficients		Standardized Coefficients	t	Sig.
		B	Std. Error	Beta		
1	(Constant)	6.548	.211		31.026	.000
	Age of respondent, calculated	-.017	.004	-.111	-4.081	.000



a. Dependent Variable: Household's total net income, all sources

F.eks: inntekt og alder fra «Sosial ulikhet»

- Annengradsledd → ta variabelen i en høyere potens.
 - Ta variabelen, og gang den med seg selv.
 - Inkluder begge variablene (originale, og den i annengradspotensi) i regresjonen.


Inntekt målt ved en ordinalvariabel

1 Kr 123 000 eller mindre
2 Kr 124 000 til 230 000
3 Kr 231 000 til 306 000
4 Kr 307 000 til 369 000
5 Kr 370 000 til 434 000
6 Kr 435 000 til 493 000
7 Kr 494 000 til 557 000
8 Kr 558 000 til 658 000
9 Kr 659 000 til 856 000
10 Kr 857 000 eller mer




F.eks: inntekt og alder fra «Sosial ulikhet»

Dersom annengradsledd er:
- negativ: har den et toppunkt før den faller igjen



Dersom annengradsledd er:
- positiv: øker den eksponentielt



Variables Entered/Removed^a

Model	Variables Entered	Variables Removed	Method
1	Alder12, Age of respondent, calculated ^b		Enter

a. Dependent Variable: Household's total net income, all sources

b. All requested variables entered.

Model Summary

Model	R	R Square	Adjusted R Square	Std. Error of the Estimate
1	.283 ^a	.080	.079	2.608

a. Predictors: (Constant), Alder12, Age of respondent, calculated

ANOVA^a

Model		Sum of Squares	df	Mean Square	F	Sig.
1	Regression	795.116	2	397.558	58.437	.000 ^b
	Residual	9143.460	1344	6.803		
	Total	9938.576	1346			

a. Dependent Variable: Household's total net income, all sources

b. Predictors: (Constant), Alder12, Age of respondent, calculated

Coefficients^a

Model		Unstandardized Coefficients		Standardized Coefficients Beta	t	Sig.
		B	Std. Error			
1	(Constant)	2.228	.480		4.644	.000
	Age of respondent, calculated	.191	.021	1.256	8.983	.000
	Alder12	-.002	.000	-1.391	-9.950	.000

a. Dependent Variable: Household's total net income, all sources

Inkludert annengradsledd,
(alder * alder)

F.eks: inntekt og alder fra «Sosial ulikhet»

- Regresjonsanalyse med annengradsledd indikerer at toppunktet nås ved 50,2 år
 - Se Johannessen, Christoffersen & Tufte for detaljer og utregning

Variables Entered/Removed^a

Model	Variables Entered	Variables Removed	Method
1	Age of respondent, calculated ^b		Enter

a. Dependent Variable: Household's total net income, all sources

b. All requested variables entered.

Model Summary

Model	R	R Square	Adjusted R Square	Std. Error of the Estimate
1	.111 ^a	.012	.011	2.702

a. Predictors: (Constant), Age of respondent, calculated

ANOVA^a

Model		Sum of Squares	df	Mean Square	F	Sig.
1	Regression	121.534	1	121.534	16.651	.000 ^b
	Residual	9817.042	1345	7.299		
	Total	9938.576	1346			

a. Dependent Variable: Household's total net income, all sources

b. Predictors: (Constant), Age of respondent, calculated

Coefficients^a

Model		Unstandardized Coefficients		Standardized Coefficients Beta	t	Sig.
		B	Std. Error			
1	(Constant)	6.548	.211		31.026	.000
	Age of respondent, calculated	-.017	.004	-.111	-4.081	.000

a. Dependent Variable: Household's total net income, all sources

Variables Entered/Removed^a

Model	Variables Entered	Variables Removed	Method
1	Alder12, Age of respondent, calculated ^b		Enter

a. Dependent Variable: Household's total net income, all sources

b. All requested variables entered.

Model Summary

Model	R	R Square	Adjusted R Square	Std. Error of the Estimate
1	.283 ^a	.080	.079	2.608

a. Predictors: (Constant), Alder12, Age of respondent, calculated

ANOVA^a

Model		Sum of Squares	df	Mean Square	F	Sig.
1	Regression	795.116	2	397.558	58.437	.000 ^b
	Residual	9143.460	1344	6.803		
	Total	9938.576	1346			

a. Dependent Variable: Household's total net income, all sources

b. Predictors: (Constant), Alder12, Age of respondent, calculated

Coefficients^a

Model		Unstandardized Coefficients		Standardized Coefficients Beta	t	Sig.
		B	Std. Error			
1	(Constant)	2.228	.480		4.644	.000
	Age of respondent, calculated	.191	.021	1.256	8.983	.000
	Alder12	-.002	.000	-1.391	-9.950	.000

a. Dependent Variable: Household's total net income, all sources

Inkludert annengradsledd,
(alder * alder)

Eksempel boligpriser

Eiendomsdata - modellen som skal estimeres:

- $Y = b_0 + b_1 X_1 + b_2 X_2 + b_3 X_3 + b_4 X_4$
 - Y = salgspris
 - X_1 = boligareal (kvadrat meter)
 - X_2 = beliggenhet
 - X_3 = boligens energimerking
 - X_4 = type bolig
- Modellen kan også skrives som:
 - $\text{Salgspris} = \text{basispris} + b_1 * \text{boligareal} + b_2 * \text{beliggenhet} + b_3 * \text{boligens energimerking} + b_4 * \text{type bolig}$

F.eks: inntekt og alder fra «Sosial ulikhet»

- Regresjonsanalyse med annengradsledd indikerer at toppunktet nås ved 50,2 år
 - Se Johannessen, Christoffersen & Tufte for detaljer og utregning

Variables Entered/Removed^a

Model	Variables Entered	Variables Removed	Method
1	Age of respondent, calculated ^b	.	Enter

a. Dependent Variable: Household's total net income, all sources

b. All requested variables entered.

Model Summary

Model	R	R Square	Adjusted R Square	Std. Error of the Estimate
1	.111 ^a	.012	.011	2.702

a. Predictors: (Constant), Age of respondent, calculated

ANOVA^a

Model		Sum of Squares	df	Mean Square	F	Sig.
1	Regression	121.534	1	121.534	16.651	.000 ^b
	Residual	9817.042	1345	7.299		
	Total	9938.576	1346			

a. Dependent Variable: Household's total net income, all sources

b. Predictors: (Constant), Age of respondent, calculated

Variables Entered/Removed^a

Model	Variables Entered	Variables Removed	Method
1	Alder12, Age of respondent, calculated ^b	.	Enter

a. Dependent Variable: Household's total net income, all sources

b. All requested variables entered.

Model Summary

Model	R	R Square	Adjusted R Square	Std. Error of the Estimate
1	.283 ^a	.080	.079	2.608

a. Predictors: (Constant), Alder12, Age of respondent, calculated

ANOVA^a

Model		Sum of Squares	df	Mean Square	F	Sig.
1	Regression	795.116	2	397.558	58.437	.000 ^b
	Residual	9143.460	1344	6.803		
	Total	9938.576	1346			

a. Dependent Variable: Household's total net income, all sources

b. Predictors: (Constant), Alder12, Age of respondent, calculated

Coefficients^a

Model		Unstandardized Coefficients		Standardized Coefficients Beta	t	Sig.
		B	Std. Error			
1	(Constant)	6.548	.211		31.026	.000
	Age of respondent, calculated	-.017	.004	-.111	-4.081	.000

a. Dependent Variable: Household's total net income, all sources

Coefficients^a

Model		Unstandardized Coefficients		Standardized Coefficients Beta	t	Sig.
		B	Std. Error			
1	(Constant)	2.228	.480		4.644	.000
	Age of respondent, calculated	.191	.021	1.256	8.983	.000
	Alder12	-.002	.000	-1.391	-9.950	.000

a. Dependent Variable: Household's total net income, all sources

Inkludert annengradsledd, (alder * alder)

Nesten åtte ganger så mye forklart varians

Begge er signifikante



- Alder går fra liten negativ, til ganske stor positiv, som forventet
- Annengradspotensi er negativ, og stor, som viser topp punkt for inntekt ikke er linjert

F.eks: inntekt og alder fra «Sosial ulikhet»

- Annengradsledd $\rightarrow$ ta variabelen i en høyere potens.
- Regresjonsanalyse med annengradsledd indikerer at toppunktet nås ved 50,2 år
 - Se Johannessen, Christoffersen & Tufte for detaljer.


Inntekt målt ved en ordinalvariabel

1 Kr 123 000 eller mindre
2 Kr 124 000 til 230 000
3 Kr 231 000 til 306 000
4 Kr 307 000 til 369 000
5 Kr 370 000 til 434 000
6 Kr 435 000 til 493 000
7 Kr 494 000 til 557 000
8 Kr 558 000 til 658 000
9 Kr 659 000 til 856 000
10 Kr 857 000 eller mer



F.eks: inntekt og alder fra «Sosial ulikhet»

- Koding av data: variable «inntekt»



K19_6	K19_7	Alder2	Inntekt_kopi	Inntekt_2
1	0	256.00	10	100
1	0	2304.00	8	64
1	0	1764.00	2	4
1	0	441.00	5	25
1	0	625.00	9	81
0	0	2601.00	8	64

Fungerer så
lenge det er
definert i
variabelen i
SPSS

Name	Type	Width	Decimals	Label	Values	Missing	Columns	Align	Measure	Role
1 proddate	String	10	0	Production date	None	None	12	Left	Scale	Input
2 idno	Numeric	5	0	Respondent's i...	None	None	8	Right	Nominal	Input
3 cntry	Numeric	8	0	Land	{1, Norway}...	None	8	Right	Nominal	Input
4 A2	Numeric	1	0	Internet use, h...	{1, Never}...	7, 8, 9	14	Right	Nominal	Input
5 A3	Numeric	4	0	Internet use, h...	{6666, Not applicable}...	7777, 9999, 6666	12	Right	Scale	Input
6 B1	Numeric	2	0	Number of peo...	{77, Refusal}...	77, 88, 99	8	Right	Scale	Input
7 B2	Numeric	1	0	Gender	{1, Male}...	9	8	Right	Nominal	Input
8 B3	Numeric	4	0	Year of birth	{7777, Refusal}...	7777, 8888, 9999	8	Right	Scale	Input
9 agea	Numeric	3	0	Age of respond...	{999, Not available}...	999	8	Right	Scale	Input
10 B4	Numeric	1	0	Domicile, resp...	{1, A big city}...	7, 8, 9	8	Right	Nominal	Input
11 B5_no	Numeric	4	0	Highest level of...	{1, Ingen fullført utdanning}...	7777, 8888, 9999	8	Right	Nominal	Input
12 B5_uk1	Numeric	4	0	Highest level of...	{1, 2 or more A-levels or e...	7777, 8888, 9999	8	Right	Nominal	Input
13 B5uk2	Numeric	4	0	Highest level of...	{1, Ph.D, D.Phil or equival...	7777, 8888, 9999	8	Right	Nominal	Input
14 B6	Numeric	2	0	Years of full-ti...	{77, Refusal}...	77, 88, 99	8	Right	Scale	Input
15 B7	Numeric	2	0	Main activity, la...	{1, Paid work}...	66 - 99	8	Right	Nominal	Input
16 B8	Numeric	2	0	Main source of ...	{1, Wages or salaries}...	77, 88, 99	8	Right	Nominal	Input
17 B9	Numeric	2	0	Household's to...	{1, J - 1st decile}...	77, 88, 99	8	Right	Nominal	Input
18 R10	Numeric	1	0	Feeling about ...	{1, Living comfortably on a...	7, 8, 9	8	Right	Nominal	Input

I SPSS ser det ut til at disse ikke blir inkludert, ved standard, ved analyser, inkludert deskriptiv statistikk, og regresjon.

Blir behandlet som «missing» når nye variabler lages.

MERK: ikke ta dette for gitt, sjekk!

- (bruker du Excel i tillegg, er det IKKE standard)

F.eks: inntekt og alder fra «Sosial ulikhet»

- Koding av data: variable «inntekt»
 - Forskjellige resultat i SPSS og Excel, på grunn av koding.

The screenshot shows an Excel spreadsheet with two columns: 'Income' and 'Age'. The data is as follows:

	A	B
1	Income	Age
2	6	55
3	8	58
4	5	35
5	9	18
6	4	22
7	4	57
8	10	48
9	10	46
10	3	35
11	8	30

Below the data, a summary box contains the following information:

Median income	6
Mean income	9.386251
Correlation	-0.166983

Statistics

	Valid	Missing
N	1347	64
Mean	5.74	
Median	6.00	
Range	9	

Household's total net income, all sources

	Frequency	Percent	Valid Percent	Cumulative Percent
Valid J - 1st decile	90	6.7	5.9	5.9
R - 2nd decile	120	8.5	8.9	14.8
C - 3rd decile	136	9.6	10.1	24.9
M - 4th decile	151	10.7	11.2	36.2
F - 5th decile	144	10.2	10.7	46.8
S - 6th decile	148	10.5	11.0	57.8
K - 7th decile	165	11.7	12.2	70.1
P - 8th decile	134	9.5	9.9	80.0
D - 9th decile	124	8.8	9.2	89.2
H - 10th decile	145	10.3	10.8	100.0
Total	1347	95.5	100.0	
Missing Refusal	11	.8		
Don't know	53	3.8		
Total	64	4.5		
Total	1411	100.0		

Correlations

		Household's total net income, all sources	Age of respondent, calculated
Household's total net income, all sources	Pearson Correlation	1	-.111**
	Sig. (2-tailed)		.000
N		1347	1347
Age of respondent, calculated	Pearson Correlation	-.111**	1
	Sig. (2-tailed)	.000	
N		1347	1411

** . Correlation is significant at the 0.01 level (2-tailed).

Forutsetninger: Fravær av **multikollinearitet**


- Multikollinearitet = graden av lineær sammenheng mellom to eller flere forklaringsvariabler
 - Problem: vanskelig/ikke mulig å skille effekten av hver variabel på den avhengige, når begge beveger seg likt.
- Multikollinearitet **øker standardfeilen** til parameterestimatene, noe som igjen påvirker t-verdien
- Kjør alltid en korrelasjonsanalyse for å se på bivariate sammenhenger i dataene.
 - Johannesen m.fl.: «Dersom Pearsons r mellom to uavhengige variabler er mer enn 0,7 har vi kollinearitetsproblemer»
- VIF-analyse («variance-inflation-factor»)

Forutsetninger: Fravær av multikolaritet

- VIF-analyse («variance-inflation-factor»)
- Klikk på «Statistics» i menyen for «Linear regression» og huk av for «Collinearity diagnostics»
 - Når VIF er >5 , noe å undersøke
 - Når VIF er >10 , er det problematisk


Coefficients ^a								
Model		Unstandardized Coefficients		Standardized Coefficients	t	Sig.	Collinearity Statistics	
		B	Std. Error	Beta			Tolerance	VIF
1	(Constant)	1189120,291	192995,011		6,161	<,001		
	BOA/P-rom	36526,904	782,684	,805	46,669	,000	,413	2,421
	Beliggenhet Oslo vest	1097854,352	65786,981	,190	16,688	<,001	,946	1,057
	Energimerking	-89749,107	20734,477	-,048	-4,328	<,001	,983	1,018
	Leilighet	-31922,546	116187,228	-,006	-,275	,784	,268	3,727
	Rekkehus	-182299,476	112367,316	-,023	-1,622	,105	,596	1,679
	Tomannsbolig	236594,386	118806,136	,027	1,991	,047	,683	1,465

a. Dependent Variable: Salgspris



Forutsetninger: Residualene

- Brudd har konsekvenser for statistisk generalisering
 - Uavhengighet blant observasjonene
 - **Homoskedastisitet**; spredningen rundt regresjonslinja skal være konstant for alle verdier av x (dvs. residualene skal ha konstant varians)
 - Normalfordelte residualer

$$Y = a + bX_i + e$$


Restledd


Andre **ukjente** faktorer (variabler) – denne kan vi ikke beregne, men kan benyttes til å teste **forutsetningene**

Eksempel boligpriser

Eiendomsdata - modellen som skal estimeres:

- $Y = b_0 + b_1 X_1 + b_2 X_2 + b_3 X_3 + b_4 X_4 + e$
 - Y = salgspris
 - X_1 = boligareal
 - X_2 = beliggenhet
 - X_3 = boligens energimerking
 - X_4 = type bolig
- Modellen kan også skrives som:
 - Salgspris = basispris + b_1 *boligareal + b_2 *beliggenhet + b_3 * boligens energimerking + b_4 * type bolig + residual

Residualer er det som ikke er forklart av modellen (her i bivariat)





- Etter at alle variablene er tatt med for å estimere utfallsvariabel, skal det som ikke blir forklart, være like mye for lave verdier av utfallsvariabelen, som for høye.
- F.eks. boligpris: det som ikke blir forklart ved alle variabler (residualene /e) skal være like mye for små boliger, som for store boliger.
- Dersom dette ikke er tilfelle (heteroskedasitet), kan det bety at estimatene ikke er korrekte.

$$Y = b_0 + b_1 X_1 + b_2 X_2 + b_3 X_3 + b_4 X_4 + e$$

$$\text{Salgspris} = \text{basispris} + b_1 * \text{boligareal} + b_2 * \text{beliggenhet} + b_3 * \text{boligens energimerking} + b_4 * \text{type bolig} + \text{residual}$$

Forutsetninger: Test for homoskedastisitet

- Eiendomsdata
 - Klikk på «Plots» i menyen for «Linear regression»
 - Legg inn «ZPRED» som X-variabel og «ZRESID» som Y-variabel



Forutsetninger: Test for homoskedastisitet

- Formell test: Breusch–Pagan test
- Konsekvens:
 - Standardfeilen blir gal => kan ikke stole på signifikanstesten



Tiltak:

- Weighted eller generalized least squares
- Beregn korrigerede/robuste standardfeil (ikke mulig i SPSS)
- Transformere y , x (eller begge) via logaritmer

Forutsetninger: Test for normalfordelte residualer

Eiendomsdata

- Klikk på «Explore» i menyen for «Descriptive Statistics»
- Legg den lagrede residualvariabelen inn i variabellista
- Klikk «Plots» og huk av for «Histogram» og «Normality plots with tests»




Forutsetninger: Test for normalfordelte residualer

- H_0 : Residualene er normalfordelte
 - $\rightarrow H_0$ forkastes

Konsekvens: Kan ikke stole på t -verdien og signifikanstesten

Primært et problem i små utvalg (Under 100-120 observasjoner)



Descriptives			
		Statistic	Std. Error
Standardized Residual	Mean	,0000000	,02218926
	95% Confidence Interval for Mean		
	Lower Bound	-,0435162	
	Upper Bound	,0435162	
	5% Trimmed Mean	-,0341666	
	Median	-,0307950	
	Variance	,997	
	Std. Deviation	,99851669	
	Minimum	-3,29323	
	Maximum	7,41963	
	Range	10,71286	
	Interquartile Range	1,03843	
	Skewness	1,220	,054
	Kurtosis	6,770	,109



Tests of Normality						
	Kolmogorov-Smirnov ^a			Shapiro-Wilk		
	Statistic	df	Sig.	Statistic	df	Sig.
Unstandardized Residual	,079	2025	<,001	,927	2025	<,001
a. Lilliefors Significance Correction						

Forutsetninger: **Kurtosis og Skewness**

- Antar at fordeling av observasjonene er normalfordelt
 - Ikke lener til en side
 - Ikke har for mange ekstremverdier




Descriptive Statistics										
	N Statistic	Minimum Statistic	Maximum Statistic	Mean		Std. Deviation Statistic	Skewness		Kurtosis	
				Statistic	Std. Error		Statistic	Std. Error	Statistic	Std. Error
Salgspris	2027	1100000	27000000	4969774,00	59707,353	2688157,410	1,493	,054	4,152	,109
BOA/P-rom	2031	18	449	107,70	1,316	59,291	1,107	,054	1,422	,109
Valid N (listwise)	2026									

Forutsetninger: Test for normalfordelte residualer

- Kan også testes med z-score
 - $Z = (\text{Observed Kurtosis} - 3) / (\text{Standard Error of Kurtosis})$
 - $Z = \text{Skewness} / \text{Standard error of skewness}$
- For 95% konfidens: test mot om er innenfor -1.96 to 1.96.

Descriptives			
		Statistic	Std. Error
Standardized Residual	Mean	,0000000	,02218926
	95% Confidence Interval for Mean		
	Lower Bound	-,0435162	
	Upper Bound	,0435162	
	5% Trimmed Mean	-,0341666	
	Median	-,0307950	
	Variance	,997	
	Std. Deviation	,99851669	
	Minimum	-3,29323	
	Maximum	7,41963	
	Range	10,71286	
	Interquartile Range	1,03843	
	Skewness	1,220	,054
	Kurtosis	6,770	,109



Descriptive Statistics										
	N	Minimum	Maximum	Mean		Std. Deviation	Skewness		Kurtosis	
	Statistic	Statistic	Statistic	Statistic	Std. Error	Statistic	Statistic	Std. Error	Statistic	Std. Error
Salgspris	2027	1100000	27000000	4969774,00	59707,353	2688157,410	1,493	,054	4,152	,109
BOA/P-rom	2031	18	449	107,70	1,316	59,291	1,107	,054	1,422	,109
Valid N (listwise)	2026									

Forutsetninger: fravær av **Endogenitet**

- Endogenitet: at det er en systematisk sammenheng (korrelasjon) mellom en uavhengig variable og residualene (e). ($\text{cov}(\epsilon_i, x) \neq 0$)
- Vanlige kilder inkluderer
 - To-veis effekt: avhengig variable påvirker en (eller flere) uavhengige
 - Manglede variable som både påvirker avhengig og er korrelert med en uavhengig variable
 - Målefeil i
 - Omvendt kausalitet (temmelig likt to-veis effekt)

Konsekvenser for brudd på forutsetninger

- **Endogenitet**, $\text{cov}(\epsilon_i, x) \neq 0$, er det mest alvorlige bruddet
 - Kan ikke stole på estimerte koeffisientverdier
 - Kan ikke stole på standardavvik, t-verdier eller p-verdier
 - Ingen perfekte tester for å avdekke
- Øvrige brudd:
 - Kan ikke kan stole på standardavvik, t-verdier eller p-verdier
 - Finnes tester for å sjekke (VIF, punktdiagrammer og normalitetstester).
- Minst alvorlig er bruddet på normalitet, spesielt hvis du har mange observasjoner (mer enn 200-300).