


Datavisualisering

Njål Andersen

Datavisualisering av 69 000 personer, på 120 variabler



Plan for timen

- Univariat
- Bivariat
- Multivariat
- Inspirasjon til videre visualiseringer

Univariat analyse (beskriv data/informasjon i en variabel)

1. Frekvens - hvor mange (absolutt og relativt) har svart på de ulike alternativene?
2. Sentraltendens (hva er det typiske svaret?)
 - Modus
 - Median
 - Gjennomsnitt
3. Spredning (variasjon rundt sentraltendensen)
 - Normert modalprosent
 - Minimum-/maksimumsverdier
 - Variasjonsbredde
 - Varians
 - Standardavvik


1. Frekvens

Absolutt og relativ fordeling av svar

Tabell 14.1 Absolutt og relativ fordeling på spørsmålet «Hvordan vil du karakterisere ditt forhold til din nærmeste overordnede?» (N = 200)


Svaralternativer	Antall respondenter	Proporsjon	Prosent (proporsjon x 100)
Meget godt (5)	n = 50	$(50/200) = 0,25$	$(0,25 \times 100) = 25 \%$
Godt (4)	n = 60	$(60/200) = 0,30$	$(0,30 \times 100) = 30 \%$
Verken godt eller dårlig (3)	n = 30	$(30/200) = 0,15$	$(0,15 \times 100) = 15 \%$
Dårlig (2)	n = 30	$(30/200) = 0,15$	$(0,15 \times 100) = 15 \%$
Svært dårlig (1)	n = 30	$(30/200) = 0,15$	$(0,15 \times 100) = 15 \%$

Forhold til leder



- Meget godt
- Godt
- Verken godt eller dårlig
- Dårlig
- Svært dårlig

Forhold til leder



- Meget godt
- Godt
- Verken godt eller dårlig
- Dårlig
- Svært dårlig

Kakediagram...

- Tidvis populære.. Men:
 - Vanskelig å sammenlikne
 - Små biter kan bli vanskelig å merke og se
 - Gir stort sett lite positivt


Absolutt og relativ fordeling av svar (stolpediagram)

Tabell 14.1 Absolutt og relativ fordeling på spørsmålet «Hvordan vil du karakterisere ditt forhold til din nærmeste overordnede?» (N = 200)

Svaralternativer	Antall respondenter	Proporsjon	Prosent (proporsjon x 100)
Meget godt (5)	n = 50	$(50/200) = 0,25$	$(0,25 \times 100) = 25 \%$
Godt (4)	n = 60	$(60/200) = 0,30$	$(0,30 \times 100) = 30 \%$
Verken godt eller dårlig (3)	n = 30	$(30/200) = 0,15$	$(0,15 \times 100) = 15 \%$
Dårlig (2)	n = 30	$(30/200) = 0,15$	$(0,15 \times 100) = 15 \%$
Svært dårlig (1)	n = 30	$(30/200) = 0,15$	$(0,15 \times 100) = 15 \%$


Stolpediagram: når det er få alternativer

- Likert skala (1-5, 1-7, etc.)
- Kategoriske variabler (boligtype, sosial media kanal)




Stolpediagram (bar chart): muligheter


- Y akse kan representere:
 - Antall
 - Prosjenter
 - Relativ andel



create a bar chart for "boligtype", with absolute counts on the y axis. Give the count at the top of each bar




recreate it, with percentages




update it, with a single bar, with each type represented with a different tranche, summing up to 100%

Stolpediagram (bar chart): muligheter


- X-aksen kan organiseres:
 - Etter stigende kategori
 - Fra størst til minst
 - Med farger



create a bar chart for the variable "energi"




please use a colour scheme to indicate size of bars, where small bars are dark, large are bright



update it, with a single color, with largest group to left, and each group decending by size


Svar fordeling - histogram




Figur 14.3 Fordeling på spørsmålet «Hva er din alder» (N = 2896). Histogram.

Histogram: for numeriske/forholdstall


- Bestem antall stolper (bins)
 - En for hver numerisk verdi? (blir fort MANGE)
 - Mange? Få?



create a histogram of the variable "Pris", with 10 bins.
make x-axis in millions of kroner



recreate it, with 20 bins



recreate it, with 40 bins

Se på koden, for siste tilpassninger

Rediger tittel og akser her, så det står det du vil ha

Analyzed ^

python

```
# Create histogram for "pris" in million kroner with 40 bins
fig, ax = plt.subplots(figsize=(10, 6))
ax.set_facecolor("white") # Set white background

# Plot histogram with 40 bins
counts, bins, patches = plt.hist(df['pris_mill'].dropna(), bins=40, color="royalblue", edgecolor='black')

# Format x-axis with evenly spaced ticks in million kroner
ax.set_xticks(bins[::4]) # Show every fourth bin to avoid clutter
ax.set_xticklabels([f"{b:.1f}" for b in bins[::4]], rotation=45, ha='right', fontsize=12) # 1

# Labels and title
plt.xlabel("Pris (Millioner kroner)", fontsize=14)
plt.ylabel("Frequency", fontsize=14)
plt.title("Histogram of Pris (Millioner kroner, 40 bins)", fontsize=16)
plt.grid(axis='y', linestyle='--', alpha=0.7)

# Show the plot
plt.show()
```

2. Sentraltendens

.. Hvor «midten» i dataen er

Type variable og mulige sentraltendens mål

- Kategorisk (nominalt)
 - F.eks. foretrekker du storfe, lam, kylling, fisk eller vegan
- Rangordning (ordinalt)
 - F.eks. sett rekkefølgen du foretrekker følge drikker: Coca Cola, Solo, Urge, Red Bull, kaffe og vann.
 - Kan ikke si noe om hvor mye bedre første-valget er enn andre valg
- Metrisk (forholdstall)
 - F.eks. alder, høyde, inntekt
 - Kan si noe om relative verdier
- Binært
 - F.eks. «er du fysisk til stedet»?
 - Kun to alternativer

Tabell 14.3 Sammenheng mellom ulike statistiske mål på sentraltendens og variablers målenivå

		Mål på sentraltendens		
		Modus	Median	Gjennomsnitt
Målenivå	Kategorisk (nominalt)	x		
	Rangordning (ordinalt)	x	x	(x)
	Metrisk (forholdstall)	x	x	x


Mål på sentraltendens og type variable

- **Modus:** alternative flest har valgt/mest vanlig
- **Median:** punktet der 50% er over og 50% under – midtpunktet
- **Gjennomsnitt / (mean):** Snittverdi av alle svar

Tabell 14.3 Sammenheng mellom ulike statistiske mål på sentraltendens og variablers målenivå

		Mål på sentraltendens		
		Modus	Median	Gjennomsnitt
Målenivå	Kategorisk (nominalt)	x		
	Rangordning (ordinalt)	x	x	(x)
	Metrisk (forholdstall)	x	x	x

Fordeling av alder: median og modus




Figur 14.6 Fordeling på variabelen alder i form av stolpediagram. Modus og median angitt.

Hva sier hver av disse? Hva sier de samlet?


Hva mest informativ? Hva mer ønsker vi?

Figure 1. Distribution of Household Income, 2019



Source: U.S. Census Bureau, *Annual Social and Economic Supplement*, available at <https://www.census.gov/data/tables/time-series/demo/income-poverty/cps-hinc/hinc-06.html>.

Forskjell på sentraltendser: antall underordnede



Figur 14.7 Fordeling på variabelen «antall underordnede» i form av stolpediagram. Modus, median og gjennomsnitt angitt.

3. Spredning av observasjoner

Mål på spredning


- Normert modalprosent
 - Hvilken andel som er på modalen
- Minimum- maksimum
 - Lavest og høyest verdi
- Variasjonsbredde
 - Forskjell på høyest og lavest
- Standardavvik
 - Mål på spredning i svarene

Tabell 14.4 Sammenheng mellom ulike statistiske mål på spredning og variabelers målenivå

		Mål på spredning			
		Normert modalprosent	Minimum – maksimum	Variasjonsbredde	Standardavvik
Målenivå	Kategorisk (nominalt)	x			
	Rangordning (ordinalt)	x	x	x	(x)
	Metrisk (forholdstall)	x	x	x	x


Standardavvik (ca. tall)


- Ca. 68,2% av alle svar er innenfor +/- **ett standardavvik**
- Ca. 95,4% av alle svar er innenfor +/- to standardavvik



Indikerer hvordan fordelingen ser ut

- Sort linje:
 - fordeling av svært lav standardavvik
- Turkis linje
 - fordeling har stort standardavvik






Figur 14.8 Fordeling på variabelen alder i form av stolpediagram. Gjennomsnitt og ulike mål på spredning angitt.

Visualiser sentraltendens og spredning


- *“please give me the mean, mode, median, Standard deviation, and IRQ for the variable "Pris. Give results with two decimal places”*

Statistic	Value
Mean	4969774.00
Median	4375000.00
Mode	2550000.00
Standard Deviation	2688157.41
Interquartile Range	3605000.00


Visualiser sentraltendens og spredning



create a histogram of the variable "Pris", with 10 bins.
make x-axis in millions of kroner



update it, marking the standard deviation
and IRQ



update the graph so that values that are
two standard deviations or more away are
one colour, those that are within 1
standard deviation, another color

Boxplot graf for univariat

- Boksen (box): viser median og 25% og 75% grenser av verdiene.
- Linjene (whiskers): viser 1.5x 25% av verdiene.
- Sirkler for vise ekstremverdier




create a boxplot for "Pris"

Det er mange måter å visualisere data på..


Alternative visualisering.. «Violin plot»

Merk: de grå stiplede linjene representerer (fra venstre til høyre): 25 percentile, Median, 75 percentile)



Violin plot, all variables, truncated to possible range

«Passe
Mengde»



Bivariat Analyse

Samvariasjon mellom to variabler

- Krysstabeller
- Sammenligning av gjennomsnitt
- Spredningsdiagram
- Korrelasjonsanalyse

Hypoteseutvikling

Slutningsstatistikk/statistisk generalisering

Bivariat analyse – oversikt

- Krysstabeller
- Spredningsplott
- Statistiske mål på samvariasjon
 - Phi
 - Pearsons r (produktmomentkorrelasjonskoeffisienten)
 - Gamma
 - Kendall Tau
 - Rho (rangkorrelasjonskoeffisienten)

Krysstabeller

- Viser frekvens av observasjoner, organisert etter **kategori** og variabel
 - Kombinerer data for (minst) to variabler
- Viser forhold og mønster i dataen
- Kan brukes for å teste statistisk om forhold mellom variabler

Krysstabeller

Are you considering staying in norway when you finish your degree/programme? * Gender Crosstabulation

			Gender		
			Female	Male	Total
Are you considering staying in norway when you finish your degree/programme?	Yes	Count	260	240	500
		% within Gender	66,2%	58,7%	62,3%
	No	Count	133	169	302
		% within Gender	33,8%	41,3%	37,7%
Total	Count		393	409	802
	% within Gender		100,0%	100,0%	100,0%



Prosentuer



Sammenlign

Begrensninger av krysstabeller

- Blir fort svært store/ mange
 - Ved flere svaralternativer
 - (f.eks. inntekt, høyde, alder)
 - Ved flere variabler
- Vanskelig å få oversikt

Table 4. Cross tabulation scores by gender and age group and frequency distributions of responses to Q8L7 of Swedish respondents in 2013, showing number (percentage) who selected each response.

Age	Gender	Strongly agree		Agree		Somewhat agree		Somewhat disagree		Disagree		Strongly disagree		Total	
20s	Men	7	(7.0)	20	(20.0)	32	(32.0)	21	(21.0)	13	(13.0)	7	(7.0)	100	(100.0)
	Women	15	(14.6)	36	(35.0)	24	(23.3)	15	(14.6)	10	(9.7)	3	(2.9)	103	(100.0)
	Both	22	(10.8)	56	(27.6)	56	(27.6)	36	(17.7)	23	(11.3)	10	(4.9)	203	(100.0)
30s	Men	8	(7.9)	21	(20.8)	37	(36.6)	13	(12.9)	12	(11.9)	10	(9.9)	101	(100.0)
	Women	13	(12.4)	26	(24.8)	35	(33.3)	21	(20.0)	7	(6.7)	3	(2.9)	105	(100.0)
	Both	21	(10.2)	47	(22.8)	72	(35.0)	34	(16.5)	19	(9.2)	13	(6.3)	206	(100.0)
40s	Men	3	(2.9)	26	(25.2)	28	(27.2)	22	(21.4)	23	(22.3)	11	(10.7)	103	(100.0)
	Women	9	(8.3)	22	(20.4)	29	(26.9)	22	(20.4)	23	(21.3)	3	(2.8)	108	(100.0)
	Both	12	(5.7)	38	(18.0)	57	(27.0)	44	(20.9)	46	(21.8)	14	(6.6)	211	(100.0)
50s	Men	4	(3.9)	10	(9.7)	25	(24.3)	19	(18.4)	33	(32.0)	12	(11.7)	103	(100.0)
	Women	6	(5.5)	18	(16.4)	32	(29.1)	23	(20.9)	22	(20.0)	9	(8.2)	110	(100.0)
	Both	10	(4.7)	28	(13.1)	57	(26.8)	42	(19.7)	55	(25.8)	21	(9.9)	213	(100.0)
60s	Men	0	0.0	5	(4.5)	32	(29.1)	26	(23.6)	37	(33.6)	10	(9.1)	110	(100.0)
	Women	7	(6.6)	14	(13.2)	43	(40.6)	15	(14.2)	23	(21.7)	4	(3.8)	106	(100.0)
	Both	7	(3.2)	19	(8.8)	75	(34.7)	41	(19.0)	60	(27.8)	14	(6.5)	216	(100.0)
Total	Men	22	(4.3)	72	(13.9)	154	(29.8)	101	(19.5)	118	(22.8)	50	(9.7)	517	(100.0)
	Women	50	(9.4)	116	(21.8)	163	(30.6)	96	(18.0)	85	(16.0)	22	(4.1)	532	(100.0)
	Both	72	(6.9)	188	(17.9)	317	(30.2)	197	(18.8)	203	(19.4)	72	(6.9)	1049	(100.0)

Table 5. Cross tabulation scores by gender and age group and frequency distributions of responses to Q8L10 of Swedish respondents in 2013, showing number (percentage) who selected each response.

Age	Gender	Strongly agree		Agree		Somewhat agree		Somewhat disagree		Disagree		Strongly disagree		Total	
20s	Men	6	(6.0)	15	(15.0)	30	(30.0)	29	(29.0)	17	(17.0)	3	(3.0)	100	(100.0)
	Women	12	(11.7)	19	(18.4)	41	(39.8)	17	(16.5)	12	(11.7)	2	(1.9)	103	(100.0)
	Both	18	(8.9)	34	(16.7)	71	(35.0)	46	(22.7)	29	(14.3)	5	(2.5)	203	(100.0)
30s	Men	10	(9.9)	12	(11.9)	29	(28.7)	23	(22.8)	18	(17.8)	9	(8.9)	101	(100.0)
	Women	13	(12.4)	18	(17.1)	31	(29.5)	23	(21.9)	16	(15.2)	4	(3.8)	105	(100.0)
	Both	23	(11.2)	30	(14.6)	60	(29.1)	46	(22.3)	34	(16.5)	13	(6.3)	206	(100.0)
40s	Men	4	(3.9)	8	(7.8)	30	(29.1)	24	(23.3)	26	(25.2)	11	(10.7)	103	(100.0)
	Women	6	(5.6)	19	(17.6)	38	(35.2)	26	(24.1)	13	(12.0)	6	(5.6)	108	(100.0)
	Both	10	(4.7)	27	(12.8)	68	(32.2)	50	(23.7)	39	(18.5)	17	(8.1)	211	(100.0)
50s	Men	4	(3.9)	5	(4.9)	18	(17.5)	31	(30.1)	30	(29.1)	15	(14.6)	103	(100.0)
	Women	7	(6.4)	13	(11.8)	33	(30.0)	20	(18.2)	27	(24.5)	10	(9.1)	110	(100.0)
	Both	11	(5.2)	18	(8.5)	51	(23.9)	51	(23.9)	57	(26.8)	25	(11.7)	213	(100.0)
60s	Men	1	(0.9)	4	(3.6)	29	(26.4)	25	(22.7)	38	(34.5)	13	(11.8)	110	(100.0)
	Women	3	(2.8)	14	(13.2)	28	(26.4)	27	(25.5)	26	(24.5)	8	(7.5)	106	(100.0)
	Both	4	(1.9)	18	(8.3)	57	(26.4)	52	(24.1)	64	(29.6)	21	(9.7)	216	(100.0)
Total	Men	25	(4.8)	44	(8.5)	136	(26.3)	132	(25.5)	129	(25.0)	51	(9.9)	517	(100.0)
	Women	41	(7.7)	83	(15.6)	171	(32.1)	113	(21.2)	94	(17.7)	30	(5.6)	532	(100.0)
	Both	66	(6.3)	127	(12.1)	307	(29.3)	245	(23.4)	223	(21.3)	81	(7.7)	1049	(100.0)

Krysstabel for Boligtype og pris

pris_bins	Enebolig	Leilighet	Rekkehus	Tomannsbolig
Very Low	0	395	9	4
Low	10	357	24	13
Medium	63	241	71	30
High	108	123	96	78
Very High	206	38	78	83


(her har pris blitt delt inn i grupper, for det var alt for mange forskjellige priser).

Boxplot graf for univariat og bivariat

- Boksen (box): viser median og 25% og 75% grenser av verdiene.
- Linjene (whiskers): viser 1.5x 25% av verdiene.
- Sirkler for vise ekstremverdier



create a boxplot for "Pris"




create a boxplot for "Pris", one boxplot for each type of "boligtype"

Bivariat analyse – oversikt


- Krysstabeller
- Spredningsplott
- Statistiske mål på samvariasjon
 - Phi
 - Pearsons r (produktmomentkorrelasjonskoeffisienten)
 - Gamma
 - Kendall Tau
 - Rho (rangkorrelasjonskoeffisienten)

Spredingsplot – visualiser samvariasjon

- Hver observasjon (respondent) er plottet i grafen
 - (dette er tiltenkt data!)




Figur 14.11 Spredningsdiagram som viser en **positiv** samvariasjon mellom variablene alder og antall fraværsdager siste år (• = én respondent, N = 25).




Figur 14.12 Spredningsdiagram som viser en **negativ** samvariasjon mellom variablene alder og antall sykefraværsdager siste år (• = én respondent, N = 25).

Spredningsplot (Scatterplot) Pris og Areal



create a scatterplot between "Pris" and "BOAProm"

Sammenlikning med resultater fra i 2022



Bivariat analyse – oversikt

- Krysstabeller
- Spredningsplott
- Statistiske mål på samvariasjon
 - Phi
 - Pearsons r (produktmomentkorrelasjonskoeffisienten)
 - Gamma
 - Kendall Tau
 - Rho (rangkorrelasjonskoeffisienten)

Statistiske mål på samvariasjon


- Phi
- Pearsons r (produktmomentkorrelasjonskoeffisienten)
- Gamma
- Kendall Tau
- Rho (rangkorrelasjonskoeffisienten)

Statistiske mål på samvariasjon (**korrelasjon**)


- Karakteristika av målene:
 - Varierer fra -1 til +1.
 - Korrelasjon på 0 betyr at det ikke er noe systematisk samvariasjon
 - Korrelasjon på -1 betyr at samvariasjonen er invers/negativ: når en går opp, går den andre ned
 - Korrelasjon på 1 betyr at samvariasjonen er positiv, at når en går opp, går den andre også opp
 - Jo høyere absolutt korrelasjon (pluss eller minus) jo sterkere er samvariasjonen
- Styrken på korrelasjonen
 - Ingen fasit, avhengig av fenomenet som vi studerer, og hvilke forventninger vi har.
 - Tommelfingerregler (positive og negative verdier):
 - $< 0,30$ = svak korrelasjon
 - $0,30 - 0,49$ = middels korrelasjon
 - $\geq 0,50$ = sterk korrelasjon
 - Husk at studiedesign kan påvirke korrelasjon!
 - Common Method Variance (CMV).

Spredingsplot – visualiser samvariasjon

- Figur 14.11 vil ha høy **positiv** korrelasjon (ca. 0.80)
- Figur 14.12 vil ha høy **negativ** korrelasjon (ca. -0.80)




Figur 14.11 Spredningsdiagram som viser en positiv samvariasjon mellom variablene alder og antall fraværsdager siste år (• = én respondent, N = 25).



Figur 14.12 Spredningsdiagram som viser en negativ samvariasjon mellom variablene alder og antall sykefraværsdager siste år (• = én respondent, N = 25).

Spredningsplot (Scatterplot) Pris og Areal





calculate the pearsons r correlation coefficient, and add this as a line to the chart

Statistiske mål på samvariasjon (korrelasjon)

- Vanlige statistiske mål på samvariasjon
 - Pearsons r (produktmomentkorrelasjonskoeffisienten)
 - Brukt for metrisk data (contineous), som er normalfordelt
 - Phi
 - Tilsvarende Pearsons r , men for binær data (ja/nei)
 - Kendall Tau
 - Mest brukt for ordinal data, og ikke normalfordelt metrisk data, og når det er noe par-data
 - Bedre i mindre datasett
 - Rho (rangkorrelasjonskoeffisienten)
 - Mest brukt for ordinal data , og ikke normalfordelt metrisk data
 - Bedre i større datasett
 - Gamma
 - Brukt for ordinal data, der det ikke er par-data

T-test: Sammenlikn to gjennomsnitt

- Er gjennomsnittsprisen for rekkehus forskjellig fra tomannsbolig?
 - run a t-test, comparing the mean price for the type of house, found in "Boligtype", for "Rekkehus" and "Tomannsbolig"
- Resultat:
 - The **t-test results** comparing the mean price of "**Rekkehus**" and "**Tomannsbolig**" are:
 - **t-statistic**: -4.67; **p-value**: 4.12×10^{-6}
 - Since the **p-value is very small (< 0.05)**, we can **reject the null hypothesis**, indicating a statistically significant difference in mean prices between **Rekkehus** and **Tomannsbolig**.



create a boxplot for the two means in the t-test

Create a distribution curve for the two categories, and overlay them on the same graph, with transparency

Kjikvadrat-test

- test for statistisk samvariasjon for **kategori-/nominalvariable**

- Tilsvarende prosess som for t-test
 - Beregnet *kji*-kvadratverdi
 - Sammenlikner med kritisk verdi i *kji-kvadrat*-fordelingen
- Eksempel:
 - Er det forskjeller mellom kvinnelige og mannlige internasjonale studenter mht om de planlegger å bli i Norge etter avsluttede studier?
 - Se tabell 15.17 for signifikansnivå og frihetsgrader

Variansanalyse (ANOVA)

(Alternative til t-test:

Når det **er flere enn 2** grupper /gjennomsnitt)

Variansanalyse (ANOVA)

(Alternative til t-test, når det er flere enn 2 grupper /snitt)


- Målenivå:
 - Avhengig variabel på metrisk nivå (men ordinal brukes også)
 - Uavhengig variabel nominalnivå (gruppe)
 - Brukes når den uavhengige variabelen har mer enn to grupper
- Eksperimenter
- Sammenligne forskjeller mellom undersøkelsesgrupper i en spørreundersøkelse:
 - Variansanalyse deler totalvariasjonen i varians innen gruppen («innengruppevariens») og varians mellom gruppene («mellomgruppevariens»).
 - tester om gjennomsnittet av variansen mellom gruppene er større enn variansen innen gruppene.

Er det prisforskjeller på leiligheter, basert på Energimerking?

- run an ANOVA test to compare the mean price for the type of "boligtype" that is "Leilighet", divided in categories of "energi"
- **Resultat:**
- The **ANOVA test results** for comparing the mean price of **Leilighet** across different **energy categories** are:
- **F-statistic:** 5.42
- **p-value:** 6.23×10^{-5}
- Since the **p-value is very small (< 0.05)**, we can **reject the null hypothesis**, indicating that there is a **statistically significant difference** in mean prices between at least some of the energy categories.

→ Vi vet nå at minst EN av typene er forskjellig fra de andre. Vet ikke hvilken, eller Hvilke!

En tilhørende stolpediagram (barchart) hjelper



please give me a bar chart showing the average price for "Leilighet", based on "energi"

please run a new ANOVA, but omit the "energi" type B"


The **ANOVA test results** after omitting energy type **"B"** are:

- **F-statistic**: 0.70
- **p-value**: 0.589

Since the **p-value is large (> 0.05)**, we **fail to reject the null hypothesis**, indicating that there is **no statistically significant difference** in mean prices among the remaining energy categories.

This suggests that the previously observed significance might have been driven largely by the presence of energy type **"B"**. Let me know if you need further insights or post-hoc analysis!

Etter ANVOA analyse 2: kanskje bedre visualisering?



please give me a bar chart showing the average price for "Leilighet", based on "energi", mark the bar for energi type B in Orange

Multivariat analyse og visualisering

3 eller flere variabler

Eksempel boligpriser

Eiendomsdata - modellen som skal estimeres:


- $Y = b_0 + b_1 X_1 + b_2 X_2 + b_3 X_3 + b_4 X_4$
 - Y = salgspris
 - X_1 = boligareal
 - X_2 = beliggenhet
 - X_3 = boligens energimerking
 - X_4 = type bolig
- Modellen kan også skrives som:
 - $\text{Salgspris} = \text{basispris} + b_1 * \text{boligareal} + b_2 * \text{beliggenhet} + b_3 * \text{boligens energimerking} + b_4 * \text{type bolig}$

Eksempel boligpriser

Eiendomsdata - modellen som skal estimeres:


- $Y = b_0 + b_1 X_1 + b_4 X_4$
 - Y = salgspris
 - X_1 = boligareal
 - X_4 = type bolig
- Modellen kan også skrives som:
 - $\text{Salgspris} = \text{basispris} + b_1 * \text{boligareal} + b_4 * \text{type bolig}$

Spredningsdiagram (scatterplot) med: pris, areal og boligtype



Create a scatterplot of "Pris" and "BOAProm". Use different colors for different values of "Boligtype"

Spredningsdiagram (scatterplot) med: pris, areal og boligtype



please recreate it, but mark the value "leilighet" in transparent

Regresjon på pris og areal

```

=====
                                OLS Regression Results
=====
Dep. Variable:                pris    R-squared:                0.713
Model:                        OLS      Adj. R-squared:           0.713
Method:                      Least Squares  F-statistic:            5022.
Date:                        Wed, 26 Feb 2025  Prob (F-statistic):      0.00
Time:                        00:21:31    Log-Likelihood:         -31604.
No. Observations:            2026      AIC:                    6.321e+04
Df Residuals:                2024      BIC:                    6.322e+04
Df Model:                    1
Covariance Type:              nonrobust
=====

```

	coef	std err	t	P> t	[0.025	0.975]
const	8.433e+05	6.64e+04	12.694	0.000	7.13e+05	9.74e+05
BOAProm	3.83e+04	540.428	70.869	0.000	3.72e+04	3.94e+04

```


=====
Omnibus:                    313.791    Durbin-Watson:            1.140
Prob(Omnibus):              0.000     Jarque-Bera (JB):         1466.995
Skew:                      0.660     Prob(JB):                 0.00
Kurtosis:                   6.954     Cond. No.                  255.
=====

```

Notes:


[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

Spredningsdiagram (scatterplot) med: pris, areal og boligtype



please add the regression line to the scatterplot, use the "magma" color scheme

Spredningsdiagram (scatterplot) med: pris, areal og boligtype, og 95% konfidens intervall



Update the chart to show the 95% confidence intervals for the regression line

OLS Regression Results

```

=====
Dep. Variable:          pris      R-squared:                0.715
Model:                  OLS      Adj. R-squared:           0.714
Method:                 Least Squares      F-statistic:          1014.
Date:                   Wed, 26 Feb 2025    Prob (F-statistic):      0.00
Time:                   00:43:35           Log-Likelihood:         -31596.
No. Observations:       2026             AIC:                   6.320e+04
Df Residuals:           2020             BIC:                   6.324e+04
Df Model:                5
Covariance Type:        nonrobust
=====

```

	coef	std err	t	P> t	[0.025	0.975]
const	7.625e+05	1.7e+05	4.485	0.000	4.29e+05	1.1e+06
BOAProm	3.81e+04	832.176	45.786	0.000	3.65e+04	3.97e+04
alder	691.0733	582.051	1.187	0.235	-450.409	1832.555
boligtype_Leilighet	4.722e+04	1.24e+05	0.380	0.704	-1.97e+05	2.91e+05
boligtype_Rekkehus	-1216.1630	1.2e+05	-0.010	0.992	-2.36e+05	2.34e+05
boligtype_Tomannsbolig	4.336e+05	1.27e+05	3.424	0.001	1.85e+05	6.82e+05

```

=====
Omnibus:                324.815      Durbin-Watson:          1.150
Prob(Omnibus):           0.000      Jarque-Bera (JB):       1536.807
Skew:                    0.683      Prob(JB):                0.00
Kurtosis:                7.042      Cond. No.                946.
=====


```

Notes:

[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

run a OLS regression: Dependent variable: Pris: Independent: BOAProm Alder and make dummy variables from "boligtype"


Grafisk fremstilling av coefficientene



create a graph showing the coefficients with the confidence interval. mark values not statistically significant different from 0 in red, the rest in blue

Det finnes mange fargepaletter

- Bruk definert paletter, slik som:




- Definer farger selv (med Hex code)
 - **`'#5cb7aa'`, `'#97d5a4'`, `'#fff1a8'`, `'#fa9b58'`, `'#ee6445'`**




Bruk grafikk med høy kvalitet!

- IKKE fordrei proporsjoner!

Riktig




GALT!




Trenger du den til å være kvadratisk (eller annen proporsjon, rediger koden!

Trenger du den til å være kvadratisk (eller annen proporsjon, rediger koden!

Riktig



Riktig




I need the figure canvas to be in a square format

Skal du bruke den i stort format, last ned som vector grafic

- Vektor grafikk kan skaleres uendelig stort

Scatterplot of Pris vs BOAProm by Boligtype with Regression Line



please let me download the figure in a vector format

- 
- Vektor grafikk kan skaleres uendelig stort

please let me download the figure in a vector format

Kilder til inspirasjon:

- https://medium.com/@borisnikolaev_57179/chatgpt-for-data-
- <https://seaborn.pydata.org/examples/index.htmlanalysis-a-beginners-guide-ab59d5ce3bce>
- <https://www.nytimes.com/column/whats-going-on-in-this-graph>
- <https://www.canva.com/graphs/>
- For all kode, prompts og arbeid for grafer i denne presentasjonen se:
 - <https://chatgpt.com/share/67be631d-d348-8008-9c55-cf96c64f11fc>